

Oceňovanie európskych opcií: Black-Scholesov model a metóda Monte Carlo

Technická správa s aplikáciou na reálne dáta (AAPL)

Ian Spika

2026-10-09

Obsah

1 Úvod	1
2 Teoretické pozadie	2
2.1 Geometrický Brownov pohyb	2
2.2 Black-Scholesova formula	2
2.3 Monte Carlo oceňovanie	3
3 Implementácia v R	3
3.1 Funkcie a parametre úlohy	3
4 Validácia: konvergencia Monte Carlo odhadu	4
4.1 Tabuľka konverencie	4
4.2 Grafická ilustrácia konverencie	4
4.3 Bonus: ázijská opcia	5
5 Aplikácia na reálne dáta: Apple Inc.	6
5.1 Vývoj ceny akcie	6
5.2 Odhad volatility z historických dát	7
5.3 Test predpokladu normality	8
5.4 Porovnanie modelových cien s trhovými	9
5.5 Volatility smile	11
5.6 Diskusia výsledkov	12
6 Záver	12
Literatúra	13

1 Úvod

Oceňovanie finančných derivátov patrí medzi najvýznamnejšie aplikácie matematiky v ekonómii. Európska kúpna opcia (call) dáva majiteľovi právo, nie však povinnosť, kúpiť podkladové aktívum za vopred dohodnutú cenu K v stanovenom čase T . Otázka, koľko má taká opcia stáť dnes, viedla v roku 1973 k zverejneniu slávneho modelu, ktorý získal Nobelovu cenu za ekonómiu — Black-Scholesovho modelu (Black a Scholes 1973; Merton 1973).

Hoci pre vanilkové európske opcie existuje uzavretá analytická formula, v praxi sa stretávame s mnohými variantmi opcií (ázijské, bariérové, americké, koš opcií), pre ktoré vzorec neexistuje a nutne sa musíme uchýliť k numerickým metódam. Najflexibilnejšou z nich je metóda Monte Carlo, ktorú do oceňovania opcií zaviedol Boyle (1977).

Cieľom tejto správy je:

1. predstaviť teoretické pozadie Black-Scholesovho modelu,
2. implementovať obe metódy oceňovania v jazyku R,
3. empiricky overiť konvergenciu Monte Carlo odhadu k analytickej hodnote a kvantifikovať jeho štatistickú chybu,
4. ukázať, prečo je Monte Carlo nevyhnutné pre exotické opcie, na príklade ázijskej opcie,
5. **aplikovať obe metódy na reálne trhové dáta** akcie Apple Inc. (AAPL) a porovnať modelové ceny so skutočnými trhovými kotáciami, čo vedie ku konceptu *implikovanej volatility*.

2 Teoretické pozadie

2.1 Geometrický Brownov pohyb

Black-Scholesov model predpokladá, že cena podkladového aktíva S_t sa riadi stochastickou diferenciálnou rovnicou

$$dS_t = \mu S_t dt + \sigma S_t dW_t, \quad (1)$$

kde μ je očakávaný výnos, σ volatilita a W_t štandardný Wienerov proces. Riešením rovnice Rovnica 1 je geometrický Brownov pohyb

$$S_T = S_0 \exp\left[\left(\mu - \frac{1}{2}\sigma^2\right)T + \sigma W_T\right], \quad (2)$$

čo plynie z Itôovej lemy (Hull 2018, kap. 14). Pre účely oceňovania v rizikovo-neutrálnej miere nahradíme μ bezrizikovou úrokovou mierou r .

2.2 Black-Scholesova formula

Cena európskej kúpnej opcie podľa Black-Scholesovho modelu je

$$C_{BS} = S_0 \Phi(d_1) - K e^{-rT} \Phi(d_2), \quad (3)$$

kde Φ je distribučná funkcia štandardného normálneho rozdelenia a

$$d_1 = \frac{\ln(S_0/K) + (r + \frac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}, \quad d_2 = d_1 - \sigma\sqrt{T}. \quad (4)$$

2.3 Monte Carlo oceňovanie

Cena opcie je v rizikovo-neutrálnej miere $\mathbb{Q}$ definovaná ako diskontovaná očakávaná výplata:

$$C = e^{-rT} \mathbb{E}^{\mathbb{Q}}[(S_T - K)^+]. \quad (5)$$

Monte Carlo odhad spočíva v generovaní n nezávislých realizácií ceny $S_T^{(i)}$ podľa rovnice Rovnica 2 a v aproximácii očakávania aritmetickým priemerom:

$$\hat{C}_{\text{MC}} = e^{-rT} \frac{1}{n} \sum_{i=1}^n (S_T^{(i)} - K)^+. \quad (6)$$

Podľa centrálnej limitnej vety je štandardná chyba odhadu rádu $\mathcal{O}(1/\sqrt{n})$ a 95 % konfidenčný interval má tvar $\hat{C}_{\text{MC}} \pm 1.96 \cdot \hat{s}/\sqrt{n}$, kde $\hat{s}$ je výberová smerodajná odchýlka diskontovaných výplat (Glasserman 2003, kap. 1).

3 Implementácia v R

3.1 Funkcie a parametre úlohy

Pre základnú validáciu metód použijeme modelové parametre typické pre krátkodobé akciové opcie. Reálne dáta AAPL spracujeme v Sekcia 5.

```
S0 <- 100      # aktualna cena podkladu
K <- 100       # realizacna cena (at-the-money)
r <- 0.05      # bezrizikova urokovka miera
sigma <- 0.20  # volatilita
T_ <- 1        # cas do expiracie (v rokoch)

bs_call <- function(S0, K, r, sigma, T_) {
  d1 <- (log(S0 / K) + (r + 0.5 * sigma^2) * T_) / (sigma * sqrt(T_))
  d2 <- d1 - sigma * sqrt(T_)
  S0 * pnorm(d1) - K * exp(-r * T_) * pnorm(d2)
}

mc_call <- function(S0, K, r, sigma, T_, n, seed = NULL) {
  if (!is.null(seed)) set.seed(seed)
  Z <- rnorm(n)
  ST <- S0 * exp((r - 0.5 * sigma^2) * T_ + sigma * sqrt(T_) * Z)
  payoff <- pmax(ST - K, 0)
  disc <- exp(-r * T_) * payoff
  est <- mean(disc)
  se <- sd(disc) / sqrt(n)
  list(estimate = est, se = se,
       ci_lo = est - 1.96 * se, ci_hi = est + 1.96 * se)
}

C_bs <- bs_call(S0, K, r, sigma, T_)
mc_result <- mc_call(S0, K, r, sigma, T_, n = 100000, seed = 42)
```

Pre modelové parametre dostávame analytickú cenu $C_{BS} = 10.4506$ a Monte Carlo odhad $\hat{C}_{MC} = 10.4345$ s 95 % konfidenčným intervalom $[10.3433, 10.5257]$.

4 Validácia: konvergencia Monte Carlo odhadu

4.1 Tabuľka konvergenzie

Aby sme overili rýchlosť konvergenzie odhadu Rovnica 6, zopakujme simuláciu pre rôzne hodnoty n . Výsledky sú zhrnuté v Tabuľka 1.

```
ns <- c(1e2, 1e3, 1e4, 1e5, 1e6)

tab <- do.call(rbind, lapply(ns, function(n) {
  res <- mc_call(S0, K, r, sigma, T_, n, seed = 2026)
  data.frame(n = n, odhad = res$estimate, se = res$se,
             chyba = abs(res$estimate - C_bs))
}))

knitr::kable(
  tab,
  col.names = c("n", "Odhad MC", "Štand. chyba", "|MC - BS|"),
  digits = 5, align = "rrrr"
)
```

Tabuľka 1: Konvergencia Monte Carlo odhadu k Black-Scholesovej cene.

n	Odhad MC	Štand. chyba	MC - BS
1e+02	9.27585	1.42180	1.17474
1e+03	10.51848	0.47218	0.06789
1e+04	10.49570	0.15020	0.04512
1e+05	10.50374	0.04678	0.05316
1e+06	10.44387	0.01471	0.00672

Z Tabuľka 1 vidíme, že štandardná chyba aj absolútna odchýlka od analytickej ceny klesajú približne ako $1/\sqrt{n}$ — pri zvýšení n o faktor 100 sa chyba zníži približne 10-násobne.

4.2 Grafická ilustrácia konvergenzie

Konvergencia bodového odhadu spolu s pásmom 95 % konfidenčného intervalu je znázornená na Obrázok 1.

```
set.seed(2026)
n_max <- 50000
Z <- rnorm(n_max)
ST <- S0 * exp((r - 0.5 * sigma^2) * T_ + sigma * sqrt(T_) * Z)
disc <- exp(-r * T_) * pmax(ST - K, 0)
```


```

cumul_mean <- cumsum(disc) / seq_along(disc)
cumul_var  <- (cumsum(disc^2) - seq_along(disc) * cumul_mean^2) /
              pmax(seq_along(disc) - 1, 1)
cumul_se   <- sqrt(cumul_var / seq_along(disc))

idx <- seq(100, n_max, by = 50)

plot(idx, cumul_mean[idx], type = "l", lwd = 1.5, col = "steelblue",
     ylim = c(C_bs - 1.5, C_bs + 1.5),
     xlab = "počet simulácií n", ylab = "odhad ceny opcie")
polygon(c(idx, rev(idx)),
       c(cumul_mean[idx] - 1.96 * cumul_se[idx],
         rev(cumul_mean[idx] + 1.96 * cumul_se[idx])),
       col = adjustcolor("steelblue", alpha.f = 0.2), border = NA)
abline(h = C_bs, lty = 2, lwd = 1.2)
legend("topright", legend = c("MC odhad", "95 % CI", "BS hodnota"),
     col = c("steelblue", adjustcolor("steelblue", 0.4), "black"),
     lty = c(1, 1, 2), lwd = c(1.5, 6, 1.2), bty = "n")

```



Obrázok 1: Konvergencia Monte Carlo odhadu ceny opcie k analytickej hodnote (čierna prerušovaná čiara) so zväčšujúcim sa počtom simulácií. Šedé pásmo predstavuje 95 % konfidenčný interval.

4.3 Bonus: ázijská opcia

Pre exotické opcie analytická formula vo všeobecnosti neexistuje a metóda Monte Carlo sa stáva nevyhnutnou. Ako príklad uvažujme **ázijskú priemerovaciu kúpnu opciu**, ktorej výplata závisí od priemeru ceny počas životnosti opcie:

$$\text{payoff} = (\bar{S} - K)^+, \quad \bar{S} = \frac{1}{m} \sum_{j=1}^m S_{t_j}. \quad (7)$$

```
mc_asian <- function(S0, K, r, sigma, T_, n, m, seed = NULL) {
  if (!is.null(seed)) set.seed(seed)
  dt <- T_ / m
  Z <- matrix(rnorm(n * m), nrow = n, ncol = m)
  log_inc <- (r - 0.5 * sigma^2) * dt + sigma * sqrt(dt) * Z
  log_S <- t(apply(log_inc, 1, cumsum))
  S_paths <- S0 * exp(log_S)
  S_avg <- rowMeans(S_paths)
  payoff <- pmax(S_avg - K, 0)
  disc <- exp(-r * T_) * payoff
  list(estimate = mean(disc), se = sd(disc) / sqrt(n))
}

asian <- mc_asian(S0, K, r, sigma, T_, n = 50000, m = 50, seed = 7)
```

Cena ázijskej opcie (5.8569) je nižšia než cena európskej opcie (10.4506): priemerovanie znižuje volatilitu výplaty, a teda aj cenu opcie (Glasserman 2003, kap. 4).

5 Aplikácia na reálne dáta: Apple Inc.

V tejto sekcii aplikujeme obe metódy na akciu **Apple Inc. (NASDAQ: AAPL)**. Dáta sú stiahnuté zo služby Yahoo Finance pomocou packagu **quantmod** a uložené v adresári **data/**. V projekte sú dáta automaticky aktualizované každý deň cez GitHub Actions.

```
prices <- read.csv("data/aapl_prices.csv")
prices$date <- as.Date(prices$date)

# Meta-info
meta_lines <- readLines("data/meta.txt")
meta <- setNames(
  trimws(sub("^[:]+:\\s*", "", meta_lines)),
  trimws(sub(":.*$", "", meta_lines))
)


S0_real <- as.numeric(meta["spot_price"])
spot_date <- meta["spot_date"]
fetched_at <- meta["fetched_at"]
```

Aktuálna cena akcie ku dňu **2026-10-08** je **\$340.42**.

5.1 Vývoj ceny akcie

Obrázok 2 zobrazuje vývoj ceny AAPL za posledné 2 roky.

```
plot(prices$date, prices$close, type = "l", lwd = 1.2, col = "steelblue",
     xlab = "dátum", ylab = "zatváracia cena (USD)",
     main = "")
grid(col = "gray80")
abline(h = SO_real, lty = 3, col = "darkgray")
```



Obrázok 2: Vývoj zatváracej ceny AAPL za posledné 2 roky. Dáta: Yahoo Finance.

5.2 Odhad volatility z historických dát

Volatilita σ je v Black-Scholesovom modeli kľúčový parameter, ktorý nie je priamo pozorovateľný. Tradičný spôsob jej odhadu je z historických logaritmických denných výnosov

$$r_t = \ln \frac{S_t}{S_{t-1}}. \quad (8)$$

Anualizovaná volatilita sa získa škálovaním smerodajnej odchýlky denných výnosov faktorom $\sqrt{252}$, kde 252 je typický počet obchodných dní v roku.

```
log_returns <- diff(log(prices$close))
log_returns <- log_returns[is.finite(log_returns)]
sigma_daily <- sd(log_returns)
sigma_hist  <- sigma_daily * sqrt(252)

mu_daily    <- mean(log_returns)
mu_annual   <- mu_daily * 252
```


Empirické hodnoty:

- denná smerodajná odchýlka výnosov: 0.0180
- **anualizovaná historická volatilita:** $\hat{\sigma}_{\text{hist}} = 0.2859$ (28.59 %)
- anualizovaný priemerný výnos: 0.1986

5.3 Test predpokladu normality

Black-Scholesov model predpokladá, že logaritmické výnosy sú normálne rozdelené. Obrázok 3 porovnáva empirické rozdelenie výnosov AAPL s prispôbenou normálnou hustotou.

```
hist(log_returns, breaks = 50, freq = FALSE,
     col = adjustcolor("steelblue", 0.6), border = "white",
     xlab = "log výnos", ylab = "hustota", main = "")
xs <- seq(min(log_returns), max(log_returns), length.out = 200)
lines(xs, dnorm(xs, mean = mu_daily, sd = sigma_daily),
     col = "red", lwd = 2)
legend("topright",
     legend = c("empirické dáta", "N(., .^2)"),
     fill = c(adjustcolor("steelblue", 0.6), NA),
     border = c("white", NA),
     lty = c(NA, 1), col = c(NA, "red"), lwd = c(NA, 2),
     bty = "n")
```



Obrázok 3: Histogram denných logaritmických výnosov AAPL s nadprispôbenou normálnou hustotou (červená čiara). Empirické dáta vykazujú výraznejšie chvosty než predpokladá normálne rozdelenie — znak tzv. *fat tails*, dobre známy problém Black-Scholesovho modelu.

Vizuálne aj kvantitatívne (Jarque-Bera test, $p\text{-hodnota} < 0e + 00$) zamietame normalitu výnosov. Špicatosť (kurtóza) je výrazne vyššia než 3 — extrémne pohyby na trhu sa vyskytujú častejšie, než by predpovedalo normálne rozdelenie. Tento jav sa nazýva *fat tails* a je jednou z hlavných výhrad voči Black-Scholesovmu modelu.

5.4 Porovnanie modelových cien s trhovými

Teraz aplikujeme obe metódy na konkrétnu sériu kúpnych opcií na AAPL. Dáta sú stiahnuté z aktuálneho option chain.

```
options_path <- "data/aapl_options.csv"
have_options <- file.exists(options_path) &&
                  file.size(options_path) > 0

opts <- read.csv(options_path)

T_real <- as.numeric(meta["years_to_expiry"])
expiry <- meta["option_expiry"]
r_real <- 0.045 # bezrizikova miera ~ 3M T-bill yield

# Implikovana volatilita: hladame sigma t.z. BS(sigma) = market_price.
# Vraciame NA ak cena lezi mimo arbitražnych hranic alebo bisekcia zlyha.
implied_vol <- function(market_price, S0, K, r, T_) {
  if (is.na(market_price) || market_price <= 0) return(NA_real_)
  # Arbitražne hranice:  $\max(0, S - K \cdot e^{-rT}) \leq C \leq S$ 
  lower <- max(0, S0 - K * exp(-r * T_))
  if (market_price < lower * 0.99 || market_price > S0) return(NA_real_)

  f <- function(sigma) bs_call(S0, K, r, sigma, T_) - market_price
  # Hladame v intervale (1%, 300%)
  tryCatch({
    res <- uniroot(f, interval = c(0.01, 3.0), tol = 1e-6)
    res$root
  }, error = function(e) NA_real_)
}

# Pre kazdu opciu spocitame: BS cenu, MC cenu, IV
opts$bs_hist <- bs_call(S0_real, opts$strike, r_real, sigma_hist, T_real)

opts$mc_hist <- sapply(opts$strike, function(K_i) {
  res <- mc_call(S0_real, K_i, r_real, sigma_hist, T_real,
                 n = 50000, seed = 1)
  res$estimate
})

opts$iv_implied <- mapply(function(price, K_i) {
  implied_vol(price, S0_real, K_i, r_real, T_real)
}, opts$market_price, opts$strike)

opts$diff_bs <- opts$market_price - opts$bs_hist

display_tab <- data.frame(
  Strike    = opts$strike,
  Bid       = opts$bid,
  Ask       = opts$ask,
  Last      = opts$last,
```

```

Trh      = opts$market_price,
BS       = opts$bs_hist,
MC       = opts$mc_hist,
Rozdiel  = opts$diff_bs,
IV       = opts$iv_implied
)

knitr::kable(display_tab,
  col.names = c("K", "Bid", "Ask", "Last", "Cena trhu",
    "BS ( _hist)", "MC ( _hist)",
    "Trh - BS", "IV"),
  digits = 4, align = "r")

```

Tabuľka 2: Porovnanie trhových cien call opcií na AAPL s modelovými cenami. *Cena trhu* je $\text{mid} = (\text{bid} + \text{ask})/2$ ak je trh otvorený, inak posledná obchodovaná cena. *BS* a *MC* používajú historickú volatilitu. *IV* je implikovaná volatilita získaná inverziou Black-Scholesovej formule.

K	Bid	Ask	Last	Cena trhu	BS (_hist)	MC (_hist)	Trh – BS	IV
300	41.70	43.15	41.27	42.425	45.8483	45.8280	-3.4233	NA
305	37.50	38.30	36.43	37.900	41.7408	41.7342	-3.8408	NA
310	33.45	34.15	33.80	33.800	37.8083	37.8134	-4.0083	0.1594
315	29.60	30.85	28.72	30.225	34.0673	34.0861	-3.8423	0.1897
320	25.90	26.60	27.17	26.250	30.5322	30.5629	-4.2822	0.1915
325	22.45	23.30	22.83	22.875	27.2145	27.2534	-4.3395	0.1998
330	19.35	19.70	19.50	19.525	24.1229	24.1719	-4.5979	0.2011
335	16.45	16.75	16.95	16.600	21.2626	21.3148	-4.6626	0.2043
340	13.80	14.10	13.95	13.950	18.6357	18.6902	-4.6857	0.2063
345	11.45	11.75	11.85	11.600	16.2407	16.2966	-4.6407	0.2079
350	9.40	9.55	9.45	9.475	14.0732	14.1265	-4.5982	0.2080
355	7.60	7.90	7.79	7.750	12.1259	12.1771	-4.3759	0.2099
360	6.10	6.35	6.20	6.225	10.3891	10.4450	-4.1641	0.2105
365	4.80	5.10	5.33	4.950	8.8513	8.9113	-3.9013	0.2111
370	3.80	4.05	3.80	3.925	7.4994	7.5648	-3.5744	0.2123
375	2.86	3.15	3.06	3.005	6.3191	6.3863	-3.3141	0.2114
380	2.30	2.45	2.39	2.375	5.2959	5.3629	-2.9209	0.2137
385	1.76	1.95	1.93	1.855	4.4147	4.4832	-2.5597	0.2154
390	1.35	1.49	1.51	1.420	3.6608	3.7263	-2.2408	0.2162
395	1.03	1.14	1.14	1.085	3.0201	3.0807	-1.9351	0.2173
400	0.79	0.84	0.83	0.815	2.4790	2.5388	-1.6640	0.2179
405	0.60	0.68	0.67	0.640	2.0248	2.0825	-1.3848	0.2207
410	0.47	0.56	0.48	0.515	1.6458	1.6995	-1.1308	0.2244
415	0.35	0.40	0.34	0.375	1.3314	1.3801	-0.9564	0.2241
420	0.27	0.32	0.32	0.295	1.0722	1.1160	-0.7772	0.2269
425	0.14	0.29	0.29	0.215	0.8595	0.8990	-0.6445	0.2271
430	0.13	0.24	0.18	0.185	0.6860	0.7174	-0.5010	0.2326
440	0.04	0.18	0.12	0.110	0.4314	0.4485	-0.3214	0.2364

i Poznámka

Zdroj cien: $\text{mid}(\text{bid}+\text{ask})/2$ · Posledná aktualizácia dát: 2026-10-09 20:24:39.232509


5.5 Volatility smile

Implikovaná volatilita ako funkcia strike-u zvyčajne nie je konštantná, hoci Black-Scholesov model predpokladá opak. Empiricky pozorovaný tvar sa nazýva **volatility smile** alebo **smirk** (Hull 2018, kap. 20).

```
valid <- !is.na(opts$iv IMPLIED) & opts$iv IMPLIED > 0.05 & opts$iv IMPLIED < 2.0

if (sum(valid) >= 3) {
  # Auto-skala s rozumným minimom
  iv_range <- range(c(opts$iv IMPLIED[valid], sigma_hist), na.rm = TRUE)
  y_lo <- max(0, iv_range[1] - 0.05)
  y_hi <- iv_range[2] + 0.05

  plot(opts$strike[valid], opts$iv IMPLIED[valid],
        type = "b", pch = 19, col = "steelblue", lwd = 2,
        ylim = c(y_lo, y_hi),
        xlab = "strike K (USD)", ylab = "implikovaná volatilita _imp")
  abline(h = sigma_hist, lty = 2, col = "darkgray", lwd = 1.5)
  abline(v = S0_real, lty = 3, col = "tomato", lwd = 1.5)
  legend("topright",
        legend = c(" implikovaná", " historická", "spot S "),
        col = c("steelblue", "darkgray", "tomato"),
        lty = c(1, 2, 3), lwd = c(2, 1.5, 1.5),
        pch = c(19, NA, NA), bty = "n")
} else {
  plot.new()
  text(0.5, 0.5,
       sprintf("Nedostatok validných opcií pre smile graf (%d).\nSkúste rerun keď je trh otv",
               sum(valid)),
       cex = 1.1)
}
```



Obrázok 4: Implikovaná volatilita call opcií AAPL ako funkcia strike-u. Vodorovná čiara označuje historickú volatilitu odhadnutú z výnosov za posledné 2 roky. Zakrivený tvar (smile/smirk) je znakom, že trh oceňuje extrémne pohyby vyššie, než predpokladá Black-Scholesov model s konštantnou volatilitou.

5.6 Diskusia výsledkov

Z Tabuľka 2 a Obrázok 4 vyplývajú tri pozorovania:

1. **Modelová cena s historickou volatilitou systematicky podhodnocuje trhové ceny.** Priemerný rozdiel je \$-2.975\$. Trh teda implicitne oceňuje volatilitu vyššie ako historický odhad.
2. **Implikovaná volatilita nie je konštantná.** Krivka v Obrázok 4 má charakteristický tvar smile/smirk: out-of-the-money put a call opcie majú vyššiu IV než at-the-money opcie.
3. **Priemerná implikovaná volatilita** je 0.211 (21.1 %), čo je o -0.075 viac než historická volatilita (0.286). Tento rozdiel sa niekedy nazýva **volatility risk premium**.

Tieto pozorovania motivujú ďalší vývoj v oblasti finančnej matematiky: modely so stochastickou volatilitou (Heston), modely s skokmi (Merton-jump-diffusion) a lokálnou volatilitou (Dupire).

6 Záver

V tejto správe sme porovnali dve metódy oceňovania európskej kúpnej opcie: analytickú Black-Scholesovu formulu a numerickú Monte Carlo simuláciu. Empiricky sme overili teoretickú rýchlosť konvergenzie $\mathcal{O}(1/\sqrt{n})$ — pri $n = 10^6$ sa Monte Carlo odhad líši od analytickej hodnoty rádovo o tisíce.

Hlavný prínos tejto práce je však v aplikácii oboch metód na **reálne trhové dáta** akcie Apple Inc. Ukázali sme, že:

- empirické rozdelenie denných výnosov AAPL nie je normálne — má výraznejšie chvosty (*fat tails*),
- Black-Scholesov model s historickou volatilitou systematicky podhodnocuje trhové ceny opcií,
- implikovaná volatilita vykazuje charakteristický tvar *volatility smile*, čo priamo protirečí predpokladu modelu o konštantnej volatilitě.

Tieto pozorovania zhrnújú jeden z najdôležitejších poznatkov modernej finančnej matematiky: hoci je Black-Scholes elegantný a stále základným nástrojom, jeho predpoklady sú v reálnom svete porušené, a praktické oceňovanie vyžaduje pokročilejšie modely. Monte Carlo simulácia pritom zostáva univerzálnym nástrojom — funguje rovnako pre Black-Scholes ako aj pre Heston či Merton-jump-diffusion, kde uzavreté formule neexistujú.

Ďalšie smery, ktorými by sa práca dala rozšíriť, zahŕňajú: techniky redukcie rozptylu (antitetické a kontrolné premenné), oceňovanie amerických opcií metódou Longstaff-Schwartz, alebo kalibráciu modelu so stochastickou volatilitou (Glasserman 2003).

Literatúra

BLACK, Fischer a Myron SCHOLLES, 1973. The Pricing of Options and Corporate Liabilities. *Journal of Political Economy*. 1973, roč. 81, č. 3, s. 637–654.

BOYLE, Phelim P., 1977. Options: A Monte Carlo Approach. *Journal of Financial Economics*. 1977, roč. 4, č. 3, s. 323–338.

GLASSERMAN, Paul, 2003. *Monte Carlo Methods in Financial Engineering*. New York: Springer. ISBN 978-0-387-00451-8.

HULL, John C., 2018. *Options, Futures, and Other Derivatives*. 10. vyd. New York: Pearson. ISBN 978-0-13-447208-9.

MERTON, Robert C., 1973. Theory of Rational Option Pricing. *The Bell Journal of Economics and Management Science*. 1973, roč. 4, č. 1, s. 141–183.