Oceňovanie európskych opcií: Black-Scholesov model a metóda Monte Carlo

Technická správa s aplikáciou na reálne dáta (AAPL)

Ian Spika

2026-10-12

Obsah

1 Úvod **1**

2 Teoretické pozadie **1**
2.1 Geometrický Brownov pohyb 1
2.2 Black-Scholesova formula 2
2.3 Monte Carlo oceňovanie 2

3 Implementácia v R **2**
3.1 Funkcie a parametre úlohy 2

4 Validácia: konvergencia Monte Carlo odhadu **3**
4.1 Tabuľka konvergencie 3
4.2 Grafická ilustrácia konvergencie 4
4.3 Bonus: ázijská opcia 5

5 Aplikácia na reálne dáta: Apple Inc. **6**
5.1 Vývoj ceny akcie 6
5.2 Odhad volatility z historických dát 7
5.3 Test predpokladu normality 7
5.4 Porovnanie modelových cien s trhovými 8
5.5 Volatility smile 11
5.6 Diskusia výsledkov 12

6 Záver **12**

Literatúra **13**

1 Úvod

Oceňovanie finančných derivátov patrí medzi najvýznamnejšie aplikácie matematiky v ekonómii. Európska kúpna opcia (call) dáva majiteľovi právo, nie však povinnosť, kúpiť podkladové aktívum za vopred dohodnutú cenu K v stanovenom čase T. Otázka, koľko má taká opcia stáť dnes, viedla v roku 1973 k zverejneniu slávneho modelu, ktorý získal Nobelovu cenu za ekonómiu — Black-Scholesovho modelu (Black a Scholes 1973; Merton 1973).

Hoci pre vanilkové európske opcie existuje uzavretá analytická formula, v praxi sa stretávame s mnohými variantmi opcií (ázijské, bariérové, americké, koš opcií), pre ktoré vzorec neexistuje a nutne sa musíme uchýliť k numerickým metódam. Najflexibilnejšou z nich je metóda Monte Carlo, ktorú do oceňovania opcií zaviedol Boyle (1977).

Cieľom tejto správy je:

1. predstaviť teoretické pozadie Black-Scholesovho modelu,
2. implementovať obe metódy oceňovania v jazyku R,
3. empiricky overiť konvergenciu Monte Carlo odhadu k analytickej hodnote a kvantifikovať jeho štatistickú chybu,
4. ukázať, prečo je Monte Carlo nevyhnutné pre exotické opcie, na príklade ázijskej opcie,
5. **aplikovať obe metódy na reálne trhové dáta** akcie Apple Inc. (AAPL) a porovnať modelové ceny so skutočnými trhovými kotáciami, čo vedie ku konceptu *implikovanej volatility*.

2 Teoretické pozadie

2.1 Geometrický Brownov pohyb

Black-Scholesov model predpokladá, že cena podkladového aktíva S_t sa riadi stochastickou diferenciálnou rovnicou

$$dS_t = \mu S_t \, dt + \sigma S_t \, dW_t, \tag{1}$$

kde μ je očakávaný výnos, σ volatilita a W_t štandardný Wienerov proces. Riešením rovnice Rovnica 1 je geometrický Brownov pohyb

$$S_T = S_0 \exp\!\left[\left(\mu - \tfrac{1}{2}\sigma^2\right) T + \sigma W_T\right], \tag{2}$$

čo plynie z Itôovej lemy (Hull 2018, kap. 14). Pre účely oceňovania v rizikovo-neutrálnej miere nahrádzame μ bezrizikovou úrokovou mierou r.

2.2 Black-Scholesova formula

Cena európskej kúpnej opcie podľa Black-Scholesovho modelu je

$$C_{\mathrm{BS}} = S_0 \, \Phi(d_1) - K e^{-rT} \, \Phi(d_2), \tag{3}$$

kde Φ je distribučná funkcia štandardného normálneho rozdelenia a

$$d_1 = \frac{\ln(S_0/K) + (r + \tfrac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}, \qquad d_2 = d_1 - \sigma\sqrt{T}. \tag{4}$$

2.3 Monte Carlo oceňovanie

Cena opcie je v rizikovo-neutrálnej miere $\mathbb{Q}$ definovaná ako diskontovaná očakávaná výplata:

$$C = e^{-rT}\,\mathbb{E}^{\mathbb{Q}}[(S_T - K)^+]\,. \tag{5}$$

Monte Carlo odhad spočíva v generovaní n nezávislých realizácií ceny $S_T^{(i)}$ podľa rovnice Rovnica 2 a v aproximácii očakávania aritmetickým priemerom:

$$\hat{C}_{\mathrm{MC}} = e^{-rT}\,\frac{1}{n}\sum_{i=1}^{n}\left(S_T^{(i)} - K\right)^+. \tag{6}$$

Podľa centrálnej limitnej vety je štandardná chyba odhadu rádu $\mathcal{O}(1/\sqrt{n})$ a 95 % konfidenčný interval má tvar $\hat{C}_{\mathrm{MC}} \pm 1{,}96 \cdot \hat{s}/\sqrt{n}$, kde $\hat{s}$ je výberová smerodajná odchýlka diskontovaných výplat (Glasserman 2003, kap. 1).

3 Implementácia v R

3.1 Funkcie a parametre úlohy

Pre základnú validáciu metód použijeme modelové parametre typické pre krátkodobé akciové opcie. Reálne dáta AAPL spracujeme v Sekcia 5.

```
S0    <- 100      # aktualna cena podkladu
K     <- 100      # realizacna cena (at-the-money)
r     <- 0.05     # bezrizikova urokova miera
sigma <- 0.20     # volatilita
T_    <- 1        # cas do expiracie (v rokoch)
```

```
bs_call <- function(S0, K, r, sigma, T_) {
  d1 <- (log(S0 / K) + (r + 0.5 * sigma^2) * T_) / (sigma * sqrt(T_))
  d2 <- d1 - sigma * sqrt(T_)
  S0 * pnorm(d1) - K * exp(-r * T_) * pnorm(d2)
}

mc_call <- function(S0, K, r, sigma, T_, n, seed = NULL) {
  if (!is.null(seed)) set.seed(seed)
  Z       <- rnorm(n)
  ST      <- S0 * exp((r - 0.5 * sigma^2) * T_ + sigma * sqrt(T_) * Z)
  payoff  <- pmax(ST - K, 0)
  disc    <- exp(-r * T_) * payoff
  est     <- mean(disc)
  se      <- sd(disc) / sqrt(n)
  list(estimate = est, se = se,
       ci_lo = est - 1.96 * se, ci_hi = est + 1.96 * se)
}

C_bs <- bs_call(S0, K, r, sigma, T_)
mc_result <- mc_call(S0, K, r, sigma, T_, n = 100000, seed = 42)
```

Pre modelové parametre dostávame analytickú cenu $C_{\text{BS}} = 10.4506$ a Monte Carlo odhad $\hat{C}_{\text{MC}} = 10.4345$ s 95 % konfidenčným intervalom $[10.3433,\ 10.5257]$.

4 Validácia: konvergencia Monte Carlo odhadu

4.1 Tabuľka konvergencie

Aby sme overili rýchlosť konvergencie odhadu Rovnica 6, zopakujme simuláciu pre rôzne hodnoty n. Výsledky sú zhrnuté v Tabuľka 1.

```
ns <- c(1e2, 1e3, 1e4, 1e5, 1e6)

tab <- do.call(rbind, lapply(ns, function(n) {
  res <- mc_call(S0, K, r, sigma, T_, n, seed = 2026)
  data.frame(n = n, odhad = res$estimate, se = res$se,
             chyba = abs(res$estimate - C_bs))
}))

knitr::kable(
  tab,
  col.names = c("n", "Odhad MC", "Štand. chyba", "|MC - BS|"),
  digits = 5, align = "rrrr"
)
```

Tabuľka 1: Konvergencia Monte Carlo odhadu k Black-Scholesovej cene.

n	Odhad MC	Štand. chyba	$\lvert MC - BS \rvert$
1e+02	9.27585	1.42180	1.17474
1e+03	10.51848	0.47218	0.06789
1e+04	10.49570	0.15020	0.04512
1e+05	10.50374	0.04678	0.05316
1e+06	10.44387	0.01471	0.00672

Z Tabuľka 1 vidíme, že štandardná chyba aj absolútna odchýlka od analytickej ceny klesajú približne ako $1/\sqrt{n}$ — pri zvýšení n o faktor 100 sa chyba zníži približne 10-násobne.

4.2 Grafická ilustrácia konvergencie

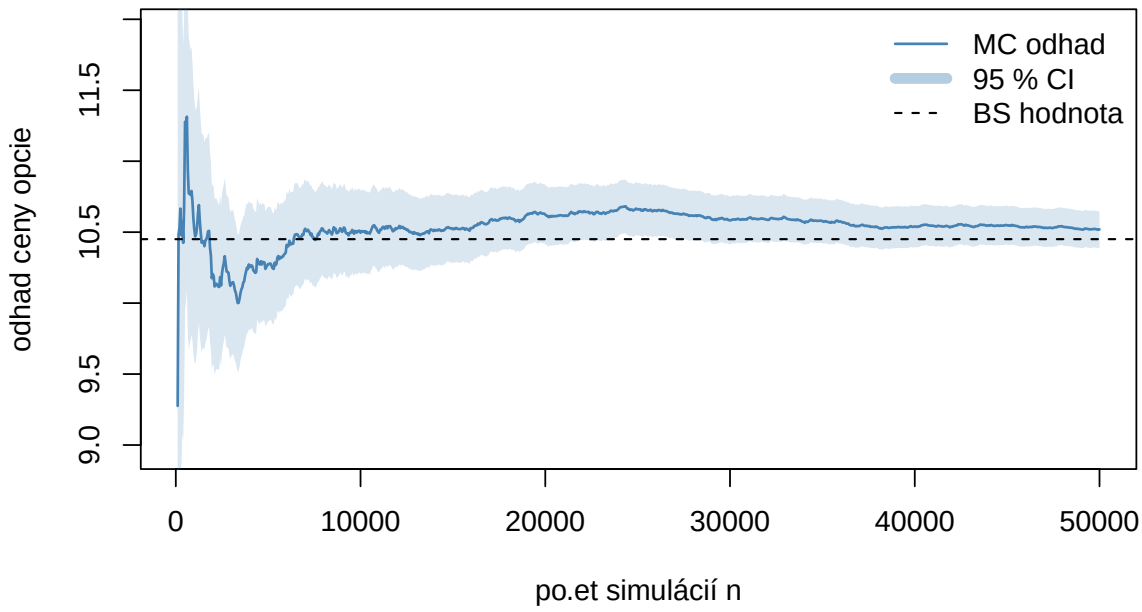
Konvergencia bodového odhadu spolu s pásmom 95 % konfidenčného intervalu je znázornená na Obrázok 1.

```
set.seed(2026)
n_max  <- 50000
Z      <- rnorm(n_max)
ST     <- S0 * exp((r - 0.5 * sigma^2) * T_ + sigma * sqrt(T_) * Z)
disc   <- exp(-r * T_) * pmax(ST - K, 0)
```

```r
cumul_mean <- cumsum(disc) / seq_along(disc)
cumul_var  <- (cumsum(disc^2) - seq_along(disc) * cumul_mean^2) /
              pmax(seq_along(disc) - 1, 1)
cumul_se   <- sqrt(cumul_var / seq_along(disc))

idx <- seq(100, n_max, by = 50)

plot(idx, cumul_mean[idx], type = "l", lwd = 1.5, col = "steelblue",
     ylim = c(C_bs - 1.5, C_bs + 1.5),
     xlab = "počet simulácií n", ylab = "odhad ceny opcie")
polygon(c(idx, rev(idx)),
        c(cumul_mean[idx] - 1.96 * cumul_se[idx],
          rev(cumul_mean[idx] + 1.96 * cumul_se[idx])),
        col = adjustcolor("steelblue", alpha.f = 0.2), border = NA)
abline(h = C_bs, lty = 2, lwd = 1.2)
legend("topright", legend = c("MC odhad", "95 % CI", "BS hodnota"),
       col = c("steelblue", adjustcolor("steelblue", 0.4), "black"),
       lty = c(1, 1, 2), lwd = c(1.5, 6, 1.2), bty = "n")
```



Obrázok 1: Konvergencia Monte Carlo odhadu ceny opcie k analytickej hodnote (čierna prerušovaná čiara) so zväčšujúcim sa počtom simulácií. Šedé pásmo predstavuje 95 % konfidenčný interval.

4.3 Bonus: ázijská opcia

Pre exotické opcie analytická formula vo všeobecnosti neexistuje a metóda Monte Carlo sa stáva nevyhnutnou. Ako príklad uvažujme **ázijskú priemerovaciu kúpnu opciu**, ktorej výplata závisí od priemeru ceny počas životnosti opcie:

$$\text{payoff} = \left(\overline{S} - K\right)^{+}, \qquad \overline{S} = \frac{1}{m}\sum_{j=1}^{m} S_{t_j}. \tag{7}$$

```r
mc_asian <- function(S0, K, r, sigma, T_, n, m, seed = NULL) {
  if (!is.null(seed)) set.seed(seed)
  dt <- T_ / m
  Z  <- matrix(rnorm(n * m), nrow = n, ncol = m)
  log_inc <- (r - 0.5 * sigma^2) * dt + sigma * sqrt(dt) * Z
  log_S   <- t(apply(log_inc, 1, cumsum))
  S_paths <- S0 * exp(log_S)
  S_avg   <- rowMeans(S_paths)
  payoff  <- pmax(S_avg - K, 0)
  disc    <- exp(-r * T_) * payoff
  list(estimate = mean(disc), se = sd(disc) / sqrt(n))
}

asian <- mc_asian(S0, K, r, sigma, T_, n = 50000, m = 50, seed = 7)
```

Cena ázijskej opcie (5.8569) je nižšia než cena európskej opcie (10.4506): priemerovanie znižuje volatilitu výplaty, a teda aj cenu opcie (Glasserman 2003, kap. 4).

5 Aplikácia na reálne dáta: Apple Inc.

V tejto sekcii aplikujeme obe metódy na akciu **Apple Inc. (NASDAQ: AAPL)**. Dáta sú stiahnuté zo služby Yahoo Finance pomocou packagu `quantmod` a uložené v adresári `data/`. V projekte sú dáta automaticky aktualizované každý deň cez GitHub Actions.

```r
prices  <- read.csv("data/aapl_prices.csv")
prices$date <- as.Date(prices$date)

# Meta-info
meta_lines <- readLines("data/meta.txt")
meta <- setNames(
  trimws(sub("^[^:]+:\\s*", "", meta_lines)),
  trimws(sub(":.*$", "", meta_lines))
)

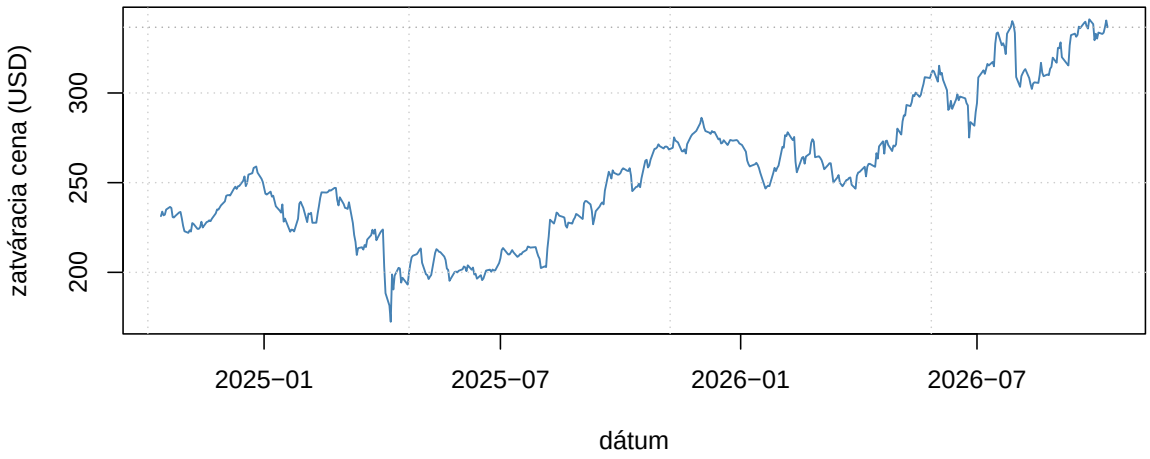
S0_real     <- as.numeric(meta["spot_price"])
spot_date   <- meta["spot_date"]
fetched_at  <- meta["fetched_at"]
```

Aktuálna cena akcie ku dňu **2026-10-09** je **$336.64**.

5.1 Vývoj ceny akcie

Obrázok 2 zobrazuje vývoj ceny AAPL za posledné 2 roky.

```r
plot(prices$date, prices$close, type = "l", lwd = 1.2, col = "steelblue",
     xlab = "dátum", ylab = "zatváracia cena (USD)",
     main = "")
grid(col = "gray80")
abline(h = S0_real, lty = 3, col = "darkgray")
```



Obrázok 2: Vývoj zatváracej ceny AAPL za posledné 2 roky. Dáta: Yahoo Finance.

5.2 Odhad volatility z historických dát

Volatilita σ je v Black-Scholesovom modeli kľúčový parameter, ktorý nie je priamo pozorovateľný. Tradičný spôsob jej odhadu je z historických logaritmických denných výnosov

$$r_t = \ln \frac{S_t}{S_{t-1}}. \tag{8}$$

Anualizovaná volatilita sa získa škálovaním smerodajnej odchýlky denných výnosov faktorom $\sqrt{252}$, kde 252 je typický počet obchodných dní v roku.

```r
log_returns <- diff(log(prices$close))
log_returns <- log_returns[is.finite(log_returns)]
sigma_daily <- sd(log_returns)
sigma_hist  <- sigma_daily * sqrt(252)

mu_daily    <- mean(log_returns)
mu_annual   <- mu_daily * 252
```

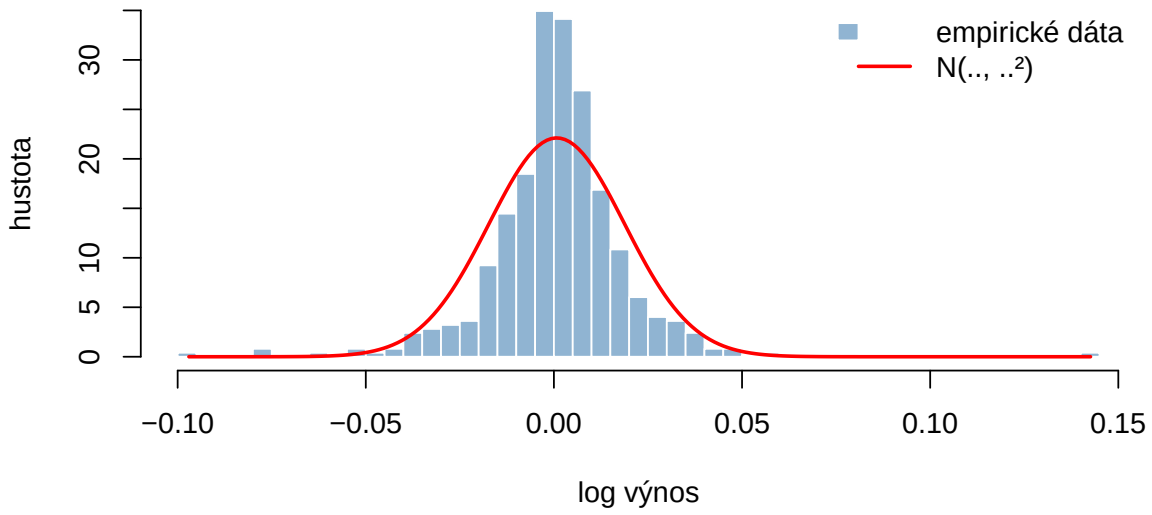
Empirické hodnoty:

- denná smerodajná odchýlka výnosov: 0.0180
- **anualizovaná historická volatilita:** $\hat{\sigma}_{\text{hist}} = 0.2864$ (28.64 %)
- anualizovaný priemerný výnos: 0.1899

5.3 Test predpokladu normality

Black-Scholesov model predpokladá, že logaritmické výnosy sú normálne rozdelené. Obrázok 3 porovnáva empirické rozdelenie výnosov AAPL s prispôsobenou normálnou hustotou.

```
hist(log_returns, breaks = 50, freq = FALSE,
     col = adjustcolor("steelblue", 0.6), border = "white",
     xlab = "log výnos", ylab = "hustota", main = "")
xs <- seq(min(log_returns), max(log_returns), length.out = 200)
lines(xs, dnorm(xs, mean = mu_daily, sd = sigma_daily),
      col = "red", lwd = 2)
legend("topright",
       legend = c("empirické dáta", "N(^, ^²)"),
       fill = c(adjustcolor("steelblue", 0.6), NA),
       border = c("white", NA),
       lty = c(NA, 1), col = c(NA, "red"), lwd = c(NA, 2),
       bty = "n")
```



Obrázok 3: Histogram denných logaritmických výnosov AAPL s nadprispôsobenou normálnou hustotou (červená čiara). Empirické dáta vykazujú výraznejšie chvosty než predpokladá normálne rozdelenie — znak tzv. *fat tails*, dobre známy problém Black-Scholesovho modelu.

Vizuálne aj kvantitatívne (Jarque-Bera test, p-hodnota $< 0e+00$) zamietame normalitu výnosov. Špicatosť (kurtóza) je výrazne vyššia než 3 — extrémne pohyby na trhu sa vyskytujú častejšie, než by predpovedalo normálne rozdelenie. Tento jav sa nazýva *fat tails* a je jednou z hlavných výhrad voči Black-Scholesovmu modelu.

5.4 Porovnanie modelových cien s trhovými

Teraz aplikujeme obe metódy na konkrétnu sériu kúpnych opcií na AAPL. Dáta sú stiahnuté z aktuálneho option chain.

```
options_path <- "data/aapl_options.csv"
have_options <- file.exists(options_path) &&
                file.size(options_path) > 0
```

```
opts <- read.csv(options_path)

T_real <- as.numeric(meta["years_to_expiry"])
expiry <- meta["option_expiry"]
r_real <- 0.045   # bezrizikova miera ~ 3M T-bill yield

# Implikovana volatilita: hladame sigma t.z. BS(sigma) = market_price.
# Vraciame NA ak cena lezi mimo arbitrážnych hranic alebo bisekcia zlyha.
implied_vol <- function(market_price, S0, K, r, T_) {
  if (is.na(market_price) || market_price <= 0) return(NA_real_)
  # Arbitražne hranice: max(0, S - K*e^-rT) <= C <= S
  lower <- max(0, S0 - K * exp(-r * T_))
  if (market_price < lower * 0.99 || market_price > S0) return(NA_real_)

  f <- function(sigma) bs_call(S0, K, r, sigma, T_) - market_price
  # Hladame v intervale (1%, 300%)
  tryCatch({
    res <- uniroot(f, interval = c(0.01, 3.0), tol = 1e-6)
    res$root
  }, error = function(e) NA_real_)
}

# Pre kazdu opciu spocitame: BS cenu, MC cenu, IV
opts$bs_hist <- bs_call(S0_real, opts$strike, r_real, sigma_hist, T_real)

opts$mc_hist <- sapply(opts$strike, function(K_i) {
  res <- mc_call(S0_real, K_i, r_real, sigma_hist, T_real,
                 n = 50000, seed = 1)
  res$estimate
})

opts$iv_implied <- mapply(function(price, K_i) {
  implied_vol(price, S0_real, K_i, r_real, T_real)
}, opts$market_price, opts$strike)

opts$diff_bs <- opts$market_price - opts$bs_hist
```

```
display_tab <- data.frame(
  Strike     = opts$strike,
  Bid        = opts$bid,
  Ask        = opts$ask,
  Last       = opts$last,
```

```
  Trh         = opts$market_price,
  BS          = opts$bs_hist,
  MC          = opts$mc_hist,
  Rozdiel     = opts$diff_bs,
  IV          = opts$iv_implied
)

knitr::kable(display_tab,
             col.names = c("K", "Bid", "Ask", "Last", "Cena trhu",
                           "BS ( _hist)", "MC ( _hist)",
                           "Trh - BS", "IV"),
             digits = 4, align = "r")
```

Tabuľka 2: Porovnanie trhových cien call opcií na AAPL s modelovými cenami. *Cena trhu* je mid (bid+ask)/2 ak je trh otvorený, inak posledná obchodovaná cena. *BS* a *MC* používajú historickú volatilitu. *IV* je implikovaná volatilita získaná inverziou Black-Scholesovej formule.

K	Bid	Ask	Last	Cena trhu	BS (_hist)	MC (_hist)	Trh − BS	IV
240	101.10	103.80	101.97	102.450	98.6390	98.5678	3.8110	0.6422
245	96.15	98.75	96.88	97.450	93.6986	93.6284	3.7514	0.6106
250	91.50	93.80	92.50	92.650	88.7696	88.7014	3.8804	0.5882
255	86.45	89.10	88.95	87.775	83.8577	83.7910	3.9173	0.5626
260	81.50	84.40	82.80	82.950	78.9699	78.9049	3.9801	0.5390
265	76.75	78.90	77.58	77.825	74.1157	74.0540	3.7093	0.5040
270	72.25	74.25	74.80	73.250	69.3066	69.2494	3.9434	0.4897
275	67.50	69.10	67.50	68.300	64.5564	64.5053	3.7436	0.4616
280	62.90	64.60	63.00	63.750	59.8810	59.8343	3.8690	0.4466
285	58.50	59.60	57.92	59.050	55.2981	55.2542	3.7519	0.4259
290	53.85	54.90	54.60	54.375	50.8270	50.7877	3.5480	0.4052
295	48.65	50.55	48.65	49.600	46.4878	46.4609	3.1122	0.3811
300	44.70	45.90	44.67	45.300	42.3007	42.2882	2.9993	0.3686
305	41.25	41.60	41.15	41.425	38.2854	38.2850	3.1396	0.3641
310	37.00	37.55	36.60	37.275	34.4603	34.4736	2.8147	0.3505
315	32.75	33.30	33.00	33.025	30.8416	30.8673	2.1834	0.3327
320	28.70	29.85	28.75	29.275	27.4429	27.4775	1.8321	0.3228
325	24.80	25.80	24.94	25.300	24.2747	24.3194	1.0253	0.3057
330	21.40	22.25	21.85	21.825	21.3438	21.3935	0.4812	0.2951
335	18.65	19.00	18.45	18.825	18.6534	18.7053	0.1716	0.2894
340	15.70	16.10	15.80	15.900	16.2031	16.2576	-0.3031	0.2811
345	13.15	13.40	13.30	13.275	13.9890	14.0409	-0.7140	0.2739
350	10.80	11.10	10.80	10.950	12.0039	12.0534	-1.0539	0.2677
355	8.70	9.00	8.80	8.850	10.2381	10.2915	-1.3881	0.2609
360	7.00	7.25	7.00	7.125	8.6795	8.7366	-1.5545	0.2565
365	5.50	5.75	5.65	5.625	7.3142	7.3771	-1.6892	0.2518
370	4.45	4.55	4.47	4.500	6.1273	6.1921	-1.6273	0.2504
375	3.25	3.55	3.25	3.400	5.1031	5.1678	-1.7031	0.2449
380	2.50	2.69	2.57	2.595	4.2257	4.2918	-1.6307	0.2422
385	1.88	2.05	1.90	1.965	3.4793	3.5420	-1.5143	0.2401

Tabuľka 2: Porovnanie trhových cien call opcií na AAPL s modelovými cenami. *Cena trhu* je mid (bid+ask)/2 ak je trh otvorený, inak posledná obchodovaná cena. *BS* a *MC* používajú historickú volatilitu. *IV* je implikovaná volatilita získaná inverziou Black-Scholesovej formule.

K	Bid	Ask	Last	Cena trhu	BS (_hist)	MC (_hist)	Trh − BS	IV
390	1.41	1.61	1.53	1.510	2.8490	2.9073	-1.3390	0.2398
395	1.09	1.22	1.03	1.155	2.3201	2.3776	-1.1651	0.2398
400	0.82	0.90	0.87	0.860	1.8794	1.9346	-1.0194	0.2389
405	0.61	0.75	0.61	0.680	1.5144	1.5650	-0.8344	0.2412
410	0.43	0.58	0.48	0.505	1.2141	1.2598	-0.7091	0.2409
415	0.32	0.48	0.38	0.400	0.9685	1.0097	-0.5685	0.2435
420	0.22	0.31	0.27	0.265	0.7689	0.8046	-0.5039	0.2394
425	0.16	0.31	0.25	0.235	0.6075	0.6351	-0.3725	0.2461
430	0.15	0.19	0.16	0.170	0.4777	0.4982	-0.3077	0.2456

i Poznámka

Zdroj cien: mid (bid+ask)/2 · Posledná aktualizácia dát: 2026-10-12 22:40:32.109823

5.5 Volatility smile

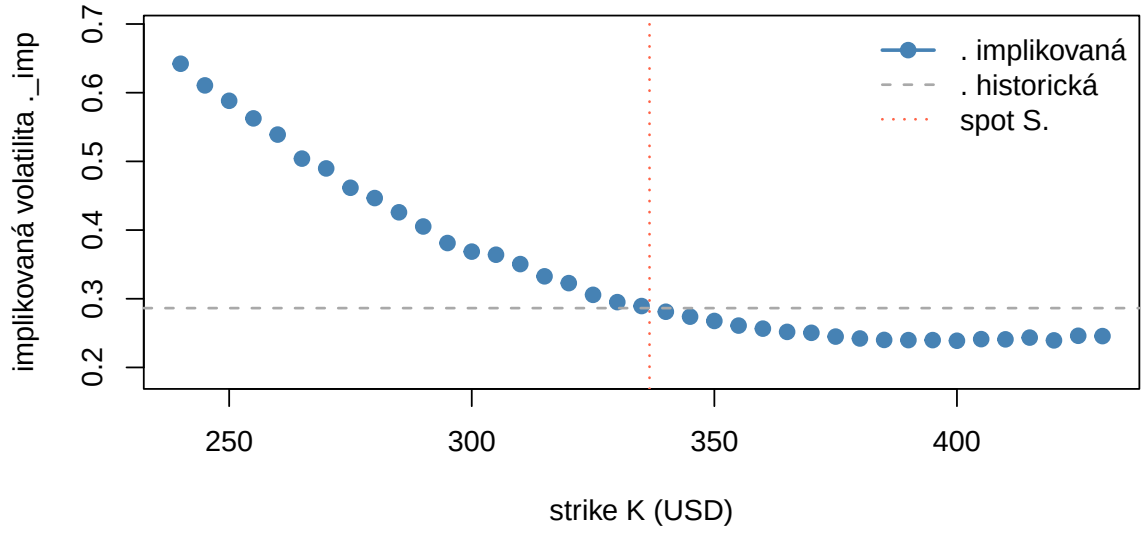
Implikovaná volatilita ako funkcia strike-u zvyčajne nie je konštantná, hoci Black-Scholesov model predpokladá opak. Empiricky pozorovaný tvar sa nazýva **volatility smile** alebo **smirk** (Hull 2018, kap. 20).

```
valid <- !is.na(opts$iv_implied) & opts$iv_implied > 0.05 & opts$iv_implied < 2.0

if (sum(valid) >= 3) {
  # Auto-skala s rozumnym minimom
  iv_range <- range(c(opts$iv_implied[valid], sigma_hist), na.rm = TRUE)
  y_lo <- max(0, iv_range[1] - 0.05)
  y_hi <- iv_range[2] + 0.05

  plot(opts$strike[valid], opts$iv_implied[valid],
       type = "b", pch = 19, col = "steelblue", lwd = 2,
       ylim = c(y_lo, y_hi),
       xlab = "strike K (USD)", ylab = "implikovaná volatilita _imp")
  abline(h = sigma_hist, lty = 2, col = "darkgray", lwd = 1.5)
  abline(v = S0_real, lty = 3, col = "tomato", lwd = 1.5)
  legend("topright",
         legend = c(" implikovaná", " historická", "spot S "),
         col = c("steelblue", "darkgray", "tomato"),
         lty = c(1, 2, 3), lwd = c(2, 1.5, 1.5),
         pch = c(19, NA, NA), bty = "n")
} else {
  plot.new()
  text(0.5, 0.5,
```

```
        sprintf("Nedostatok validných opcií pre smile graf (%d).\nSkúste rerun keď je trh otv
                sum(valid)),
        cex = 1.1)
}
```



Obrázok 4: Implikovaná volatilita call opcií AAPL ako funkcia strike-u. Vodorovná čiara označuje historickú volatilitu odhadnutú z výnosov za posledné 2 roky. Zakrivený tvar (smile/smirk) je znakom, že trh oceňuje extrémne pohyby vyššie, než predpokladá Black-Scholesov model s konštantnou volatilitou.

5.6 Diskusia výsledkov

Z Tabuľka 2 a Obrázok 4 vyplývajú tri pozorovania:

1. **Modelová cena s historickou volatilitou systematicky podhodnocuje trhové ceny.** Priemerný rozdiel je \$1.017. Trh teda implicitne oceňuje volatilitu vyššie ako historický odhad.
2. **Implikovaná volatilita nie je konštantná.** Krivka v Obrázok 4 má charakteristický tvar smile/smirk: out-of-the-money put a call opcie majú vyššiu IV než at-the-money opcie.
3. **Priemerná implikovaná volatilita** je 0.344 (34.4 %), čo je o 0.058 viac než historická volatilita (0.286). Tento rozdiel sa niekedy nazýva **volatility risk premium**.

Tieto pozorovania motivujú ďalší vývoj v oblasti finančnej matematiky: modely so stochastickou volatilitou (Heston), modely s skokmi (Merton-jump-diffusion) a lokálnou volatilitou (Dupire).

6 Záver

V tejto správe sme porovnali dve metódy oceňovania európskej kúpnej opcie: analytickú Black-Scholesovu formulu a numerickú Monte Carlo simuláciu. Empiricky sme overili teoretickú rýchlosť

konvergencie $\mathcal{O}(1/\sqrt{n})$ — pri $n = 10^6$ sa Monte Carlo odhad líši od analytickej hodnoty rádovo o tisíciny.

Hlavný prínos tejto práce je však v aplikácii oboch metód na **reálne trhové dáta** akcie Apple Inc. Ukázali sme, že:

- empirické rozdelenie denných výnosov AAPL nie je normálne — má výraznejšie chvosty (*fat tails*),
- Black-Scholesov model s historickou volatilitou systematicky podhodnocuje trhové ceny opcií,
- implikovaná volatilita vykazuje charakteristický tvar *volatility smile*, čo priamo protirečí predpokladu modelu o konštantnej volatilite.

Tieto pozorovania zhrnujú jeden z najdôležitejších poznatkov modernej finančnej matematiky: hoci je Black-Scholes elegantný a stále základným nástrojom, jeho predpoklady sú v reálnom svete porušené, a praktické oceňovanie vyžaduje pokročilejšie modely. Monte Carlo simulácia pritom zostáva univerzálnym nástrojom — funguje rovnako pre Black-Scholes ako aj pre Heston či Merton-jump-diffusion, kde uzavreté formule neexistujú.

Ďalšie smery, ktorými by sa práca dala rozšíriť, zahŕňajú: techniky redukcie rozptylu (antitetické a kontrolné premenné), oceňovanie amerických opcií metódou Longstaff-Schwartz, alebo kalibráciu modelu so stochastickou volatilitou (Glasserman 2003).

Literatúra

BLACK, Fischer a Myron SCHOLES, 1973. The Pricing of Options and Corporate Liabilities. *Journal of Political Economy*. 1973, roč. 81, č. 3, s. 637–654.

BOYLE, Phelim P., 1977. Options: A Monte Carlo Approach. *Journal of Financial Economics*. 1977, roč. 4, č. 3, s. 323–338.

GLASSERMAN, Paul, 2003. *Monte Carlo Methods in Financial Engineering*. New York: Springer. ISBN 978-0-387-00451-8.

HULL, John C., 2018. *Options, Futures, and Other Derivatives*. 10. vyd. New York: Pearson. ISBN 978-0-13-447208-9.

MERTON, Robert C., 1973. Theory of Rational Option Pricing. *The Bell Journal of Economics and Management Science*. 1973, roč. 4, č. 1, s. 141–183.