Oceňovanie európskych opcií: Black-Scholesov model a metóda Monte Carlo

Technická správa s aplikáciou na reálne dáta (AAPL)

Ian Spika

2026-11-11

Obsah

1 Úvod **1**

2 Teoretické pozadie **1**
2.1 Geometrický Brownov pohyb 1
2.2 Black-Scholesova formula 2
2.3 Monte Carlo oceňovanie 2

3 Implementácia v R **2**
3.1 Funkcie a parametre úlohy 2

4 Validácia: konvergencia Monte Carlo odhadu **3**
4.1 Tabuľka konvergencie 3
4.2 Grafická ilustrácia konvergencie 4
4.3 Bonus: ázijská opcia 5

5 Aplikácia na reálne dáta: Apple Inc. **6**
5.1 Vývoj ceny akcie 6
5.2 Odhad volatility z historických dát 7
5.3 Test predpokladu normality 7
5.4 Porovnanie modelových cien s trhovými 8
5.5 Volatility smile 11
5.6 Diskusia výsledkov 12

6 Záver **12**

Literatúra **13**

1 Úvod

Oceňovanie finančných derivátov patrí medzi najvýznamnejšie aplikácie matematiky v ekonómii. Európska kúpna opcia (call) dáva majiteľovi právo, nie však povinnosť, kúpiť podkladové aktívum za vopred dohodnutú cenu K v stanovenom čase T. Otázka, koľko má taká opcia stáť dnes, viedla v roku 1973 k zverejneniu slávneho modelu, ktorý získal Nobelovu cenu za ekonómiu — Black-Scholesovho modelu (Black a Scholes 1973; Merton 1973).

Hoci pre vanilkové európske opcie existuje uzavretá analytická formula, v praxi sa stretávame s mnohými variantmi opcií (ázijské, bariérové, americké, koš opcií), pre ktoré vzorec neexistuje a nutne sa musíme uchýliť k numerickým metódam. Najflexibilnejšou z nich je metóda Monte Carlo, ktorú do oceňovania opcií zaviedol Boyle (1977).

Cieľom tejto správy je:

1. predstaviť teoretické pozadie Black-Scholesovho modelu,
2. implementovať obe metódy oceňovania v jazyku R,
3. empiricky overiť konvergenciu Monte Carlo odhadu k analytickej hodnote a kvantifikovať jeho štatistickú chybu,
4. ukázať, prečo je Monte Carlo nevyhnutné pre exotické opcie, na príklade ázijskej opcie,
5. **aplikovať obe metódy na reálne trhové dáta** akcie Apple Inc. (AAPL) a porovnať modelové ceny so skutočnými trhovými kotáciami, čo vedie ku konceptu *implikovanej volatility*.

2 Teoretické pozadie

2.1 Geometrický Brownov pohyb

Black-Scholesov model predpokladá, že cena podkladového aktíva S_t sa riadi stochastickou diferenciálnou rovnicou

$$dS_t = \mu S_t \, dt + \sigma S_t \, dW_t, \tag{1}$$

kde μ je očakávaný výnos, σ volatilita a W_t štandardný Wienerov proces. Riešením rovnice Rovnica 1 je geometrický Brownov pohyb

$$S_T = S_0 \exp\!\left[\left(\mu - \tfrac{1}{2}\sigma^2\right) T + \sigma W_T\right], \tag{2}$$

čo plynie z Itôovej lemy (Hull 2018, kap. 14). Pre účely oceňovania v rizikovo-neutrálnej miere nahrádzame μ bezrizikovou úrokovou mierou r.

2.2 Black-Scholesova formula

Cena európskej kúpnej opcie podľa Black-Scholesovho modelu je

$$C_{\mathrm{BS}} = S_0 \, \Phi(d_1) - K e^{-rT} \, \Phi(d_2), \tag{3}$$

kde Φ je distribučná funkcia štandardného normálneho rozdelenia a

$$d_1 = \frac{\ln(S_0/K) + (r + \tfrac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}, \qquad d_2 = d_1 - \sigma\sqrt{T}. \tag{4}$$

2.3 Monte Carlo oceňovanie

Cena opcie je v rizikovo-neutrálnej miere $\mathbb{Q}$ definovaná ako diskontovaná očakávaná výplata:

$$C = e^{-rT}\,\mathbb{E}^{\mathbb{Q}}[(S_T - K)^+]\,. \tag{5}$$

Monte Carlo odhad spočíva v generovaní n nezávislých realizácií ceny $S_T^{(i)}$ podľa rovnice Rovnica 2 a v aproximácii očakávania aritmetickým priemerom:

$$\hat{C}_{\mathrm{MC}} = e^{-rT}\,\frac{1}{n}\sum_{i=1}^{n}\left(S_T^{(i)} - K\right)^+. \tag{6}$$

Podľa centrálnej limitnej vety je štandardná chyba odhadu rádu $\mathcal{O}(1/\sqrt{n})$ a 95 % konfidenčný interval má tvar $\hat{C}_{\mathrm{MC}} \pm 1{,}96 \cdot \hat{s}/\sqrt{n}$, kde $\hat{s}$ je výberová smerodajná odchýlka diskontovaných výplat (Glasserman 2003, kap. 1).

3 Implementácia v R

3.1 Funkcie a parametre úlohy

Pre základnú validáciu metód použijeme modelové parametre typické pre krátkodobé akciové opcie. Reálne dáta AAPL spracujeme v Sekcia 5.

```
S0    <- 100      # aktualna cena podkladu
K     <- 100      # realizacna cena (at-the-money)
r     <- 0.05     # bezrizikova urokova miera
sigma <- 0.20     # volatilita
T_    <- 1        # cas do expiracie (v rokoch)
```

```
bs_call <- function(S0, K, r, sigma, T_) {
  d1 <- (log(S0 / K) + (r + 0.5 * sigma^2) * T_) / (sigma * sqrt(T_))
  d2 <- d1 - sigma * sqrt(T_)
  S0 * pnorm(d1) - K * exp(-r * T_) * pnorm(d2)
}

mc_call <- function(S0, K, r, sigma, T_, n, seed = NULL) {
  if (!is.null(seed)) set.seed(seed)
  Z       <- rnorm(n)
  ST      <- S0 * exp((r - 0.5 * sigma^2) * T_ + sigma * sqrt(T_) * Z)
  payoff  <- pmax(ST - K, 0)
  disc    <- exp(-r * T_) * payoff
  est     <- mean(disc)
  se      <- sd(disc) / sqrt(n)
  list(estimate = est, se = se,
       ci_lo = est - 1.96 * se, ci_hi = est + 1.96 * se)
}

C_bs <- bs_call(S0, K, r, sigma, T_)
mc_result <- mc_call(S0, K, r, sigma, T_, n = 100000, seed = 42)
```

Pre modelové parametre dostávame analytickú cenu $C_{\text{BS}} = 10.4506$ a Monte Carlo odhad $\hat{C}_{\text{MC}} = 10.4345$ s 95 % konfidenčným intervalom $[10.3433,\ 10.5257]$.

4 Validácia: konvergencia Monte Carlo odhadu

4.1 Tabuľka konvergencie

Aby sme overili rýchlosť konvergencie odhadu Rovnica 6, zopakujme simuláciu pre rôzne hodnoty n. Výsledky sú zhrnuté v Tabuľka 1.

```
ns <- c(1e2, 1e3, 1e4, 1e5, 1e6)

tab <- do.call(rbind, lapply(ns, function(n) {
  res <- mc_call(S0, K, r, sigma, T_, n, seed = 2026)
  data.frame(n = n, odhad = res$estimate, se = res$se,
             chyba = abs(res$estimate - C_bs))
}))

knitr::kable(
  tab,
  col.names = c("n", "Odhad MC", "Štand. chyba", "|MC - BS|"),
  digits = 5, align = "rrrr"
)
```

Tabuľka 1: Konvergencia Monte Carlo odhadu k Black-Scholesovej cene.

n	Odhad MC	Štand. chyba	$\lvert MC - BS \rvert$
1e+02	9.27585	1.42180	1.17474
1e+03	10.51848	0.47218	0.06789
1e+04	10.49570	0.15020	0.04512
1e+05	10.50374	0.04678	0.05316
1e+06	10.44387	0.01471	0.00672

Z Tabuľka 1 vidíme, že štandardná chyba aj absolútna odchýlka od analytickej ceny klesajú približne ako $1/\sqrt{n}$ — pri zvýšení n o faktor 100 sa chyba zníži približne 10-násobne.

4.2 Grafická ilustrácia konvergencie

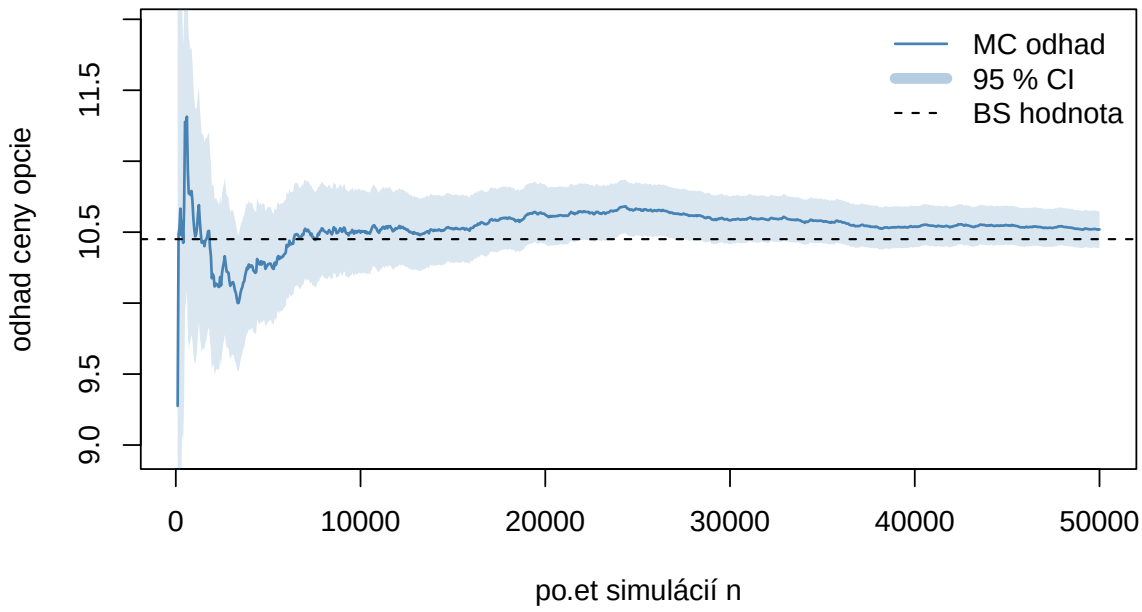
Konvergencia bodového odhadu spolu s pásmom 95 % konfidenčného intervalu je znázornená na Obrázok 1.

```
set.seed(2026)
n_max  <- 50000
Z      <- rnorm(n_max)
ST     <- S0 * exp((r - 0.5 * sigma^2) * T_ + sigma * sqrt(T_) * Z)
disc   <- exp(-r * T_) * pmax(ST - K, 0)
```

```r
cumul_mean <- cumsum(disc) / seq_along(disc)
cumul_var  <- (cumsum(disc^2) - seq_along(disc) * cumul_mean^2) /
              pmax(seq_along(disc) - 1, 1)
cumul_se   <- sqrt(cumul_var / seq_along(disc))

idx <- seq(100, n_max, by = 50)

plot(idx, cumul_mean[idx], type = "l", lwd = 1.5, col = "steelblue",
     ylim = c(C_bs - 1.5, C_bs + 1.5),
     xlab = "počet simulácií n", ylab = "odhad ceny opcie")
polygon(c(idx, rev(idx)),
        c(cumul_mean[idx] - 1.96 * cumul_se[idx],
          rev(cumul_mean[idx] + 1.96 * cumul_se[idx])),
        col = adjustcolor("steelblue", alpha.f = 0.2), border = NA)
abline(h = C_bs, lty = 2, lwd = 1.2)
legend("topright", legend = c("MC odhad", "95 % CI", "BS hodnota"),
       col = c("steelblue", adjustcolor("steelblue", 0.4), "black"),
       lty = c(1, 1, 2), lwd = c(1.5, 6, 1.2), bty = "n")
```



Obrázok 1: Konvergencia Monte Carlo odhadu ceny opcie k analytickej hodnote (čierna prerušovaná čiara) so zväčšujúcim sa počtom simulácií. Šedé pásmo predstavuje 95 % konfidenčný interval.

4.3 Bonus: ázijská opcia

Pre exotické opcie analytická formula vo všeobecnosti neexistuje a metóda Monte Carlo sa stáva nevyhnutnou. Ako príklad uvažujme **ázijskú priemerovaciu kúpnu opciu**, ktorej výplata závisí od priemeru ceny počas životnosti opcie:

$$\text{payoff} = \left(\overline{S} - K\right)^{+}, \qquad \overline{S} = \frac{1}{m}\sum_{j=1}^{m} S_{t_j}. \tag{7}$$

```r
mc_asian <- function(S0, K, r, sigma, T_, n, m, seed = NULL) {
  if (!is.null(seed)) set.seed(seed)
  dt <- T_ / m
  Z  <- matrix(rnorm(n * m), nrow = n, ncol = m)
  log_inc <- (r - 0.5 * sigma^2) * dt + sigma * sqrt(dt) * Z
  log_S   <- t(apply(log_inc, 1, cumsum))
  S_paths <- S0 * exp(log_S)
  S_avg   <- rowMeans(S_paths)
  payoff  <- pmax(S_avg - K, 0)
  disc    <- exp(-r * T_) * payoff
  list(estimate = mean(disc), se = sd(disc) / sqrt(n))
}

asian <- mc_asian(S0, K, r, sigma, T_, n = 50000, m = 50, seed = 7)
```

Cena ázijskej opcie (5.8569) je nižšia než cena európskej opcie (10.4506): priemerovanie znižuje volatilitu výplaty, a teda aj cenu opcie (Glasserman 2003, kap. 4).

5 Aplikácia na reálne dáta: Apple Inc.

V tejto sekcii aplikujeme obe metódy na akciu **Apple Inc. (NASDAQ: AAPL)**. Dáta sú stiahnuté zo služby Yahoo Finance pomocou packagu `quantmod` a uložené v adresári `data/`. V projekte sú dáta automaticky aktualizované každý deň cez GitHub Actions.

```r
prices  <- read.csv("data/aapl_prices.csv")
prices$date <- as.Date(prices$date)

# Meta-info
meta_lines <- readLines("data/meta.txt")
meta <- setNames(
  trimws(sub("^[^:]+:\\s*", "", meta_lines)),
  trimws(sub(":.*$", "", meta_lines))
)

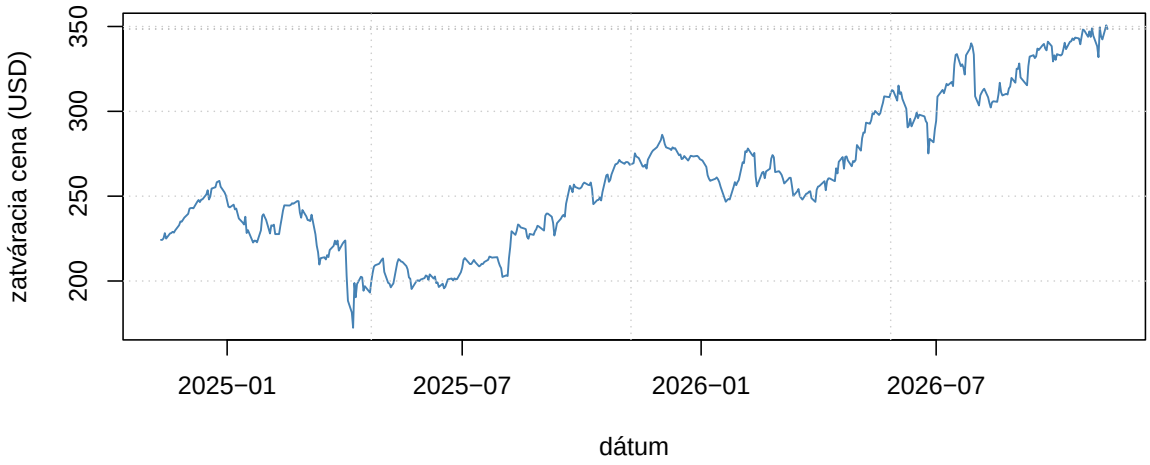
S0_real     <- as.numeric(meta["spot_price"])
spot_date   <- meta["spot_date"]
fetched_at  <- meta["fetched_at"]
```

Aktuálna cena akcie ku dňu **2026-11-10** je **$348.51**.

5.1 Vývoj ceny akcie

Obrázok 2 zobrazuje vývoj ceny AAPL za posledné 2 roky.

```r
plot(prices$date, prices$close, type = "l", lwd = 1.2, col = "steelblue",
     xlab = "dátum", ylab = "zatváracia cena (USD)",
     main = "")
grid(col = "gray80")
abline(h = S0_real, lty = 3, col = "darkgray")
```



Obrázok 2: Vývoj zatváracej ceny AAPL za posledné 2 roky. Dáta: Yahoo Finance.

5.2 Odhad volatility z historických dát

Volatilita σ je v Black-Scholesovom modeli kľúčový parameter, ktorý nie je priamo pozorovateľný. Tradičný spôsob jej odhadu je z historických logaritmických denných výnosov

$$r_t = \ln \frac{S_t}{S_{t-1}}. \tag{8}$$

Anualizovaná volatilita sa získa škálovaním smerodajnej odchýlky denných výnosov faktorom $\sqrt{252}$, kde 252 je typický počet obchodných dní v roku.

```r
log_returns <- diff(log(prices$close))
log_returns <- log_returns[is.finite(log_returns)]
sigma_daily <- sd(log_returns)
sigma_hist  <- sigma_daily * sqrt(252)

mu_daily    <- mean(log_returns)
mu_annual   <- mu_daily * 252
```

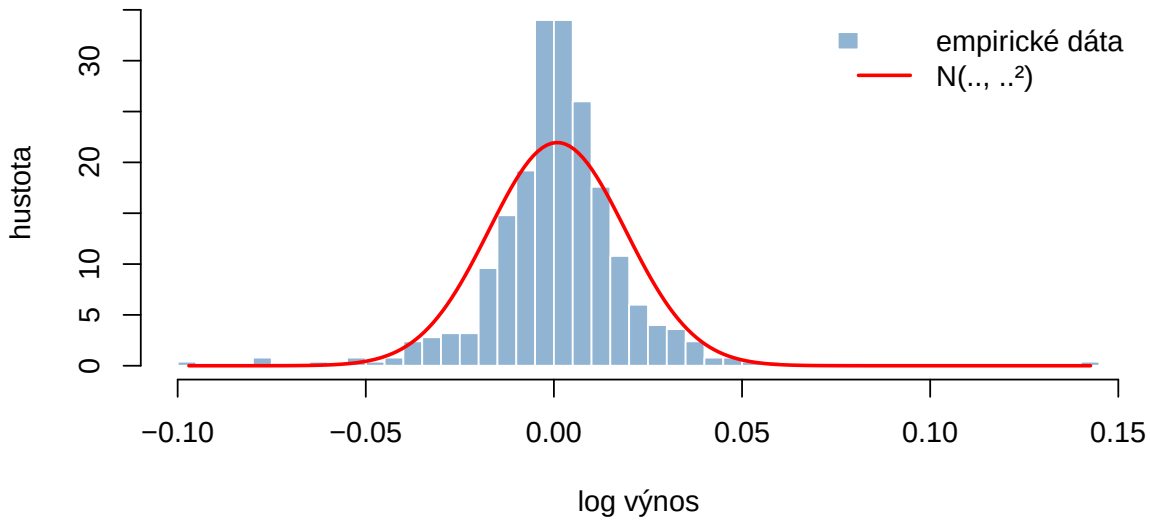
Empirické hodnoty:

- denná smerodajná odchýlka výnosov: 0.0182
- **anualizovaná historická volatilita:** $\hat{\sigma}_{\text{hist}} = 0.2885$ (28.85 %)
- anualizovaný priemerný výnos: 0.2223

5.3 Test predpokladu normality

Black-Scholesov model predpokladá, že logaritmické výnosy sú normálne rozdelené. Obrázok 3 porovnáva empirické rozdelenie výnosov AAPL s prispôsobenou normálnou hustotou.

```
hist(log_returns, breaks = 50, freq = FALSE,
     col = adjustcolor("steelblue", 0.6), border = "white",
     xlab = "log výnos", ylab = "hustota", main = "")
xs <- seq(min(log_returns), max(log_returns), length.out = 200)
lines(xs, dnorm(xs, mean = mu_daily, sd = sigma_daily),
      col = "red", lwd = 2)
legend("topright",
       legend = c("empirické dáta", "N(^, ^²)"),
       fill = c(adjustcolor("steelblue", 0.6), NA),
       border = c("white", NA),
       lty = c(NA, 1), col = c(NA, "red"), lwd = c(NA, 2),
       bty = "n")
```



Obrázok 3: Histogram denných logaritmických výnosov AAPL s nadprispôsobenou normálnou hustotou (červená čiara). Empirické dáta vykazujú výraznejšie chvosty než predpokladá normálne rozdelenie — znak tzv. *fat tails*, dobre známy problém Black-Scholesovho modelu.

Vizuálne aj kvantitatívne (Jarque-Bera test, p-hodnota $< 0e+00$) zamietame normalitu výnosov. Špicatosť (kurtóza) je výrazne vyššia než 3 — extrémne pohyby na trhu sa vyskytujú častejšie, než by predpovedalo normálne rozdelenie. Tento jav sa nazýva *fat tails* a je jednou z hlavných výhrad voči Black-Scholesovmu modelu.

5.4 Porovnanie modelových cien s trhovými

Teraz aplikujeme obe metódy na konkrétnu sériu kúpnych opcií na AAPL. Dáta sú stiahnuté z aktuálneho option chain.

```
options_path <- "data/aapl_options.csv"
have_options <- file.exists(options_path) &&
                file.size(options_path) > 0
```

```
opts <- read.csv(options_path)

T_real <- as.numeric(meta["years_to_expiry"])
expiry <- meta["option_expiry"]
r_real <- 0.045   # bezrizikova miera ~ 3M T-bill yield

# Implikovana volatilita: hladame sigma t.z. BS(sigma) = market_price.
# Vraciame NA ak cena lezi mimo arbitrážnych hranic alebo bisekcia zlyha.
implied_vol <- function(market_price, S0, K, r, T_) {
  if (is.na(market_price) || market_price <= 0) return(NA_real_)
  # Arbitražne hranice: max(0, S - K*e^-rT) <= C <= S
  lower <- max(0, S0 - K * exp(-r * T_))
  if (market_price < lower * 0.99 || market_price > S0) return(NA_real_)

  f <- function(sigma) bs_call(S0, K, r, sigma, T_) - market_price
  # Hladame v intervale (1%, 300%)
  tryCatch({
    res <- uniroot(f, interval = c(0.01, 3.0), tol = 1e-6)
    res$root
  }, error = function(e) NA_real_)
}

# Pre kazdu opciu spocitame: BS cenu, MC cenu, IV
opts$bs_hist <- bs_call(S0_real, opts$strike, r_real, sigma_hist, T_real)

opts$mc_hist <- sapply(opts$strike, function(K_i) {
  res <- mc_call(S0_real, K_i, r_real, sigma_hist, T_real,
                 n = 50000, seed = 1)
  res$estimate
})

opts$iv_implied <- mapply(function(price, K_i) {
  implied_vol(price, S0_real, K_i, r_real, T_real)
}, opts$market_price, opts$strike)

opts$diff_bs <- opts$market_price - opts$bs_hist
```

```
display_tab <- data.frame(
  Strike     = opts$strike,
  Bid        = opts$bid,
  Ask        = opts$ask,
  Last       = opts$last,
```

```
  Trh         = opts$market_price,
  BS          = opts$bs_hist,
  MC          = opts$mc_hist,
  Rozdiel     = opts$diff_bs,
  IV          = opts$iv_implied
)

knitr::kable(display_tab,
             col.names = c("K", "Bid", "Ask", "Last", "Cena trhu",
                           "BS ( _hist)", "MC ( _hist)",
                           "Trh - BS", "IV"),
             digits = 4, align = "r")
```

Tabuľka 2: Porovnanie trhových cien call opcií na AAPL s modelovými cenami. *Cena trhu* je mid (bid+ask)/2 ak je trh otvorený, inak posledná obchodovaná cena. *BS* a *MC* používajú historickú volatilitu. *IV* je implikovaná volatilita získaná inverziou Black-Scholesovej formule.

K	Bid	Ask	Last	Cena trhu	BS (_hist)	MC (_hist)	Trh − BS	IV
245	111.25	113.75	111.64	112.500	105.4813	105.4073	7.0187	0.7968
250	107.30	108.45	107.20	107.875	100.5333	100.4600	7.3417	0.7756
255	101.85	103.85	102.09	102.850	95.5933	95.5212	7.2567	0.7404
260	97.35	98.85	97.45	98.100	90.6650	90.5950	7.4350	0.7149
265	91.95	94.15	92.30	93.050	85.7540	85.6855	7.2960	0.6797
270	87.80	88.60	87.90	88.200	80.8673	80.8005	7.3327	0.6514
275	82.85	84.15	83.61	83.500	76.0138	75.9503	7.4862	0.6276
280	77.70	79.50	77.45	78.600	71.2046	71.1456	7.3954	0.5978
285	72.85	74.70	72.45	73.775	66.4527	66.3999	7.3223	0.5703
290	68.50	69.35	68.26	68.925	61.7731	61.7249	7.1519	0.5420
295	63.75	64.60	64.00	64.175	57.1827	57.1371	6.9923	0.5163
300	58.90	59.70	59.40	59.300	52.6996	52.6582	6.6004	0.4873
305	53.15	55.80	53.91	54.475	48.3426	48.3130	6.1324	0.4593
310	49.75	50.45	50.17	50.100	44.1311	44.1157	5.9689	0.4413
315	44.70	46.20	45.50	45.450	40.0837	40.0811	5.3663	0.4162
320	40.40	42.10	40.85	41.250	36.2183	36.2285	5.0317	0.3998
325	36.05	37.40	36.84	36.725	32.5505	32.5739	4.1745	0.3753
330	32.55	33.55	32.85	33.050	29.0941	29.1276	3.9559	0.3659
335	28.20	29.20	28.25	28.700	25.8595	25.9020	2.8405	0.3415
340	24.90	25.40	25.07	25.150	22.8545	22.9046	2.2955	0.3296
345	21.35	21.85	21.70	21.600	20.0830	20.1356	1.5170	0.3149
350	18.10	18.50	18.35	18.300	17.5459	17.6011	0.7541	0.3014
355	15.15	15.55	15.41	15.350	15.2406	15.2948	0.1094	0.2904
360	12.50	12.80	12.60	12.650	13.1616	13.2132	-0.5116	0.2797
365	10.10	10.45	10.20	10.275	11.3005	11.3520	-1.0255	0.2704
370	8.05	8.35	8.25	8.200	9.6468	9.7033	-1.4468	0.2619
375	6.35	6.60	6.45	6.475	8.1880	8.2501	-1.7130	0.2552
380	4.90	5.10	5.00	5.000	6.9106	6.9759	-1.9106	0.2486
385	3.75	3.95	3.85	3.850	5.7999	5.8667	-1.9499	0.2441
390	2.76	2.95	2.85	2.855	4.8408	4.9076	-1.9858	0.2383

Tabuľka 2: Porovnanie trhových cien call opcií na AAPL s modelovými cenami. *Cena trhu* je mid (bid+ask)/2 ak je trh otvorený, inak posledná obchodovaná cena. *BS* a *MC* používajú historickú volatilitu. *IV* je implikovaná volatilita získaná inverziou Black-Scholesovej formule.

K	Bid	Ask	Last	Cena trhu	BS (_hist)	MC (_hist)	Trh − BS	IV
395	1.99	2.26	2.15	2.125	4.0184	4.0859	-1.8934	0.2348
400	1.54	1.66	1.60	1.600	3.3179	3.3797	-1.7179	0.2332
410	0.85	0.93	0.91	0.890	2.2267	2.2850	-1.3367	0.2313
420	0.41	0.50	0.43	0.455	1.4644	1.5152	-1.0094	0.2281
430	0.21	0.30	0.26	0.255	0.9446	0.9860	-0.6896	0.2301
440	0.13	0.22	0.16	0.175	0.5982	0.6253	-0.4232	0.2389
450	0.07	0.09	0.09	0.080	0.3722	0.3855	-0.2922	0.2353

i Poznámka

Zdroj cien: mid (bid+ask)/2 · Posledná aktualizácia dát: 2026-11-11 22:21:54.28075

5.5 Volatility smile

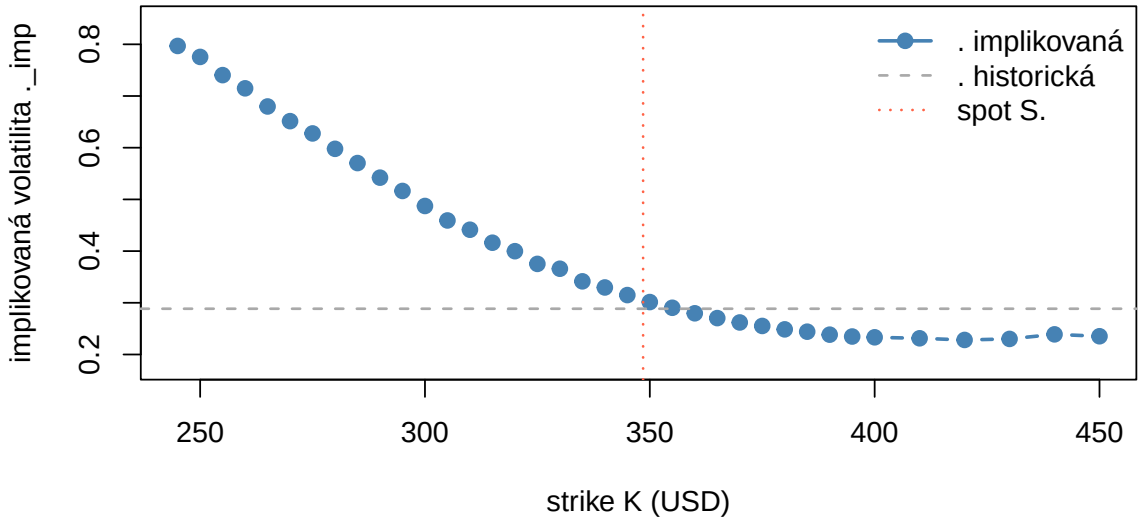
Implikovaná volatilita ako funkcia strike-u zvyčajne nie je konštantná, hoci Black-Scholesov model predpokladá opak. Empiricky pozorovaný tvar sa nazýva **volatility smile** alebo **smirk** (Hull 2018, kap. 20).

```
valid <- !is.na(opts$iv_implied) & opts$iv_implied > 0.05 & opts$iv_implied < 2.0

if (sum(valid) >= 3) {
  # Auto-skala s rozumnym minimom
  iv_range <- range(c(opts$iv_implied[valid], sigma_hist), na.rm = TRUE)
  y_lo <- max(0, iv_range[1] - 0.05)
  y_hi <- iv_range[2] + 0.05

  plot(opts$strike[valid], opts$iv_implied[valid],
       type = "b", pch = 19, col = "steelblue", lwd = 2,
       ylim = c(y_lo, y_hi),
       xlab = "strike K (USD)", ylab = "implikovaná volatilita  _imp")
  abline(h = sigma_hist, lty = 2, col = "darkgray", lwd = 1.5)
  abline(v = S0_real, lty = 3, col = "tomato", lwd = 1.5)
  legend("topright",
         legend = c("  implikovaná", "  historická", "spot S "),
         col = c("steelblue", "darkgray", "tomato"),
         lty = c(1, 2, 3), lwd = c(2, 1.5, 1.5),
         pch = c(19, NA, NA), bty = "n")
} else {
  plot.new()
  text(0.5, 0.5,
       sprintf("Nedostatok validných opcií pre smile graf (%d).\nSkúste rerun keď je trh otv
               sum(valid)),
```

```
        cex = 1.1)
}
```



Obrázok 4: Implikovaná volatilita call opcií AAPL ako funkcia strike-u. Vodorovná čiara označuje historickú volatilitu odhadnutú z výnosov za posledné 2 roky. Zakrivený tvar (smile/smirk) je znakom, že trh oceňuje extrémne pohyby vyššie, než predpokladá Black-Scholesov model s konštantnou volatilitou.

5.6 Diskusia výsledkov

Z Tabuľka 2 a Obrázok 4 vyplývajú tri pozorovania:

1. **Modelová cena s historickou volatilitou systematicky podhodnocuje trhové ceny.** Priemerný rozdiel je \$2.888. Trh teda implicitne oceňuje volatilitu vyššie ako historický odhad.
2. **Implikovaná volatilita nie je konštantná.** Krivka v Obrázok 4 má charakteristický tvar smile/smirk: out-of-the-money put a call opcie majú vyššiu IV než at-the-money opcie.
3. **Priemerná implikovaná volatilita** je 0.410 (41.0 %), čo je o 0.121 viac než historická volatilita (0.289). Tento rozdiel sa niekedy nazýva **volatility risk premium**.

Tieto pozorovania motivujú ďalší vývoj v oblasti finančnej matematiky: modely so stochastickou volatilitou (Heston), modely s skokmi (Merton-jump-diffusion) a lokálnou volatilitou (Dupire).

6 Záver

V tejto správe sme porovnali dve metódy oceňovania európskej kúpnej opcie: analytickú Black-Scholesovu formulu a numerickú Monte Carlo simuláciu. Empiricky sme overili teoretickú rýchlosť konvergencie $\mathcal{O}(1/\sqrt{n})$ — pri $n = 10^6$ sa Monte Carlo odhad líši od analytickej hodnoty rádovo o tisíciny.

Hlavný prínos tejto práce je však v aplikácii oboch metód na **reálne trhové dáta** akcie Apple Inc. Ukázali sme, že:

- empirické rozdelenie denných výnosov AAPL nie je normálne — má výraznejšie chvosty (*fat tails*),
- Black-Scholesov model s historickou volatilitou systematicky podhodnocuje trhové ceny opcií,
- implikovaná volatilita vykazuje charakteristický tvar *volatility smile*, čo priamo protirečí predpokladu modelu o konštantnej volatilite.

Tieto pozorovania zhrnujú jeden z najdôležitejších poznatkov modernej finančnej matematiky: hoci je Black-Scholes elegantný a stále základným nástrojom, jeho predpoklady sú v reálnom svete porušené, a praktické oceňovanie vyžaduje pokročilejšie modely. Monte Carlo simulácia pritom zostáva univerzálnym nástrojom — funguje rovnako pre Black-Scholes ako aj pre Heston či Merton-jump-diffusion, kde uzavreté formule neexistujú.

Ďalšie smery, ktorými by sa práca dala rozšíriť, zahŕňajú: techniky redukcie rozptylu (antitetické a kontrolné premenné), oceňovanie amerických opcií metódou Longstaff-Schwartz, alebo kalibráciu modelu so stochastickou volatilitou (Glasserman 2003).

Literatúra

BLACK, Fischer a Myron SCHOLES, 1973. The Pricing of Options and Corporate Liabilities. *Journal of Political Economy*. 1973, roč. 81, č. 3, s. 637–654.

BOYLE, Phelim P., 1977. Options: A Monte Carlo Approach. *Journal of Financial Economics*. 1977, roč. 4, č. 3, s. 323–338.

GLASSERMAN, Paul, 2003. *Monte Carlo Methods in Financial Engineering*. New York: Springer. ISBN 978-0-387-00451-8.

HULL, John C., 2018. *Options, Futures, and Other Derivatives*. 10. vyd. New York: Pearson. ISBN 978-0-13-447208-9.

MERTON, Robert C., 1973. Theory of Rational Option Pricing. *The Bell Journal of Economics and Management Science*. 1973, roč. 4, č. 1, s. 141–183.