

# Oceňovanie európskych opcií: Black-Scholesov model a metóda Monte Carlo

Technická správa s aplikáciou na reálne dáta (AAPL)

Ian Spika

2026-06-18

## Obsah

|                                                     |           |
|-----------------------------------------------------|-----------|
| <b>1 Úvod</b>                                       | <b>1</b>  |
| <b>2 Teoretické pozadie</b>                         | <b>2</b>  |
| 2.1 Geometrický Brownov pohyb                       | 2         |
| 2.2 Black-Scholesova formula                        | 2         |
| 2.3 Monte Carlo oceňovanie                          | 3         |
| <b>3 Implementácia v R</b>                          | <b>3</b>  |
| 3.1 Funkcie a parametre úlohy                       | 3         |
| <b>4 Validácia: konvergencia Monte Carlo odhadu</b> | <b>4</b>  |
| 4.1 Tabuľka konverencie                             | 4         |
| 4.2 Grafická ilustrácia konverencie                 | 4         |
| 4.3 Bonus: ázijská opcia                            | 5         |
| <b>5 Aplikácia na reálne dáta: Apple Inc.</b>       | <b>6</b>  |
| 5.1 Vývoj ceny akcie                                | 6         |
| 5.2 Odhad volatility z historických dát             | 7         |
| 5.3 Test predpokladu normality                      | 8         |
| 5.4 Porovnanie modelových cien s trhovými           | 9         |
| 5.5 Volatility smile                                | 11        |
| 5.6 Diskusia výsledkov                              | 12        |
| <b>6 Záver</b>                                      | <b>12</b> |
| <b>Literatúra</b>                                   | <b>13</b> |

## 1 Úvod

Oceňovanie finančných derivátov patrí medzi najvýznamnejšie aplikácie matematiky v ekonómii. Európska kúpna opcia (call) dáva majiteľovi právo, nie však povinnosť, kúpiť podkladové aktívum za vopred dohodnutú cenu  $K$  v stanovenom čase  $T$ . Otázka, koľko má taká opcia stáť dnes, viedla v roku 1973 k zverejneniu slávneho modelu, ktorý získal Nobelovu cenu za ekonómiu — Black-Scholesovho modelu (Black a Scholes 1973; Merton 1973).

Hoci pre vanilkové európske opcie existuje uzavretá analytická formula, v praxi sa stretávame s mnohými variantmi opcií (ázijské, bariérové, americké, koš opcií), pre ktoré vzorec neexistuje a nutne sa musíme uchýliť k numerickým metódam. Najflexibilnejšou z nich je metóda Monte Carlo, ktorú do oceňovania opcií zaviedol Boyle (1977).

Cieľom tejto správy je:

1. predstaviť teoretické pozadie Black-Scholesovho modelu,
2. implementovať obe metódy oceňovania v jazyku R,
3. empiricky overiť konvergenciu Monte Carlo odhadu k analytickej hodnote a kvantifikovať jeho štatistickú chybu,
4. ukázať, prečo je Monte Carlo nevyhnutné pre exotické opcie, na príklade ázijskej opcie,
5. **aplikovať obe metódy na reálne trhové dáta** akcie Apple Inc. (AAPL) a porovnať modelové ceny so skutočnými trhovými kotáciami, čo vedie ku konceptu *implikovanej volatility*.

## 2 Teoretické pozadie

### 2.1 Geometrický Brownov pohyb

Black-Scholesov model predpokladá, že cena podkladového aktíva  $S_t$  sa riadi stochastickou diferenciálnou rovnicou

$$dS_t = \mu S_t dt + \sigma S_t dW_t, \quad (1)$$

kde  $\mu$  je očakávaný výnos,  $\sigma$  volatilita a  $W_t$  štandardný Wienerov proces. Riešením rovnice Rovnica 1 je geometrický Brownov pohyb

$$S_T = S_0 \exp\left[\left(\mu - \frac{1}{2}\sigma^2\right)T + \sigma W_T\right], \quad (2)$$

čo plynie z Itôovej lemy (Hull 2018, kap. 14). Pre účely oceňovania v rizikovo-neutrálnej miere nahradíme  $\mu$  bezrizikovou úrokovou mierou  $r$ .

### 2.2 Black-Scholesova formula

Cena európskej kúpnej opcie podľa Black-Scholesovho modelu je

$$C_{BS} = S_0 \Phi(d_1) - K e^{-rT} \Phi(d_2), \quad (3)$$

kde  $\Phi$  je distribučná funkcia štandardného normálneho rozdelenia a

$$d_1 = \frac{\ln(S_0/K) + (r + \frac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}, \quad d_2 = d_1 - \sigma\sqrt{T}. \quad (4)$$

## 2.3 Monte Carlo oceňovanie

Cena opcie je v rizikovo-neutrálnej miere  $\mathbb{Q}$  definovaná ako diskontovaná očakávaná výplata:

$$C = e^{-rT} \mathbb{E}^{\mathbb{Q}}[(S_T - K)^+]. \quad (5)$$

Monte Carlo odhad spočíva v generovaní  $n$  nezávislých realizácií ceny  $S_T^{(i)}$  podľa rovnice Rovnica 2 a v aproximácii očakávania aritmetickým priemerom:

$$\hat{C}_{\text{MC}} = e^{-rT} \frac{1}{n} \sum_{i=1}^n (S_T^{(i)} - K)^+. \quad (6)$$

Podľa centrálnej limitnej vety je štandardná chyba odhadu rádu  $\mathcal{O}(1/\sqrt{n})$  a 95 % konfidenčný interval má tvar  $\hat{C}_{\text{MC}} \pm 1.96 \cdot \hat{s}/\sqrt{n}$ , kde  $\hat{s}$  je výberová smerodajná odchýlka diskontovaných výplat (Glasserman 2003, kap. 1).

## 3 Implementácia v R

### 3.1 Funkcie a parametre úlohy

Pre základnú validáciu metód použijeme modelové parametre typické pre krátkodobé akciové opcie. Reálne dáta AAPL spracujeme v Sekcia 5.

```
S0 <- 100      # aktualna cena podkladu
K <- 100       # realizacna cena (at-the-money)
r <- 0.05      # bezrizikova urokovka miera
sigma <- 0.20  # volatilita
T_ <- 1        # cas do expiracie (v rokoch)

bs_call <- function(S0, K, r, sigma, T_) {
  d1 <- (log(S0 / K) + (r + 0.5 * sigma^2) * T_) / (sigma * sqrt(T_))
  d2 <- d1 - sigma * sqrt(T_)
  S0 * pnorm(d1) - K * exp(-r * T_) * pnorm(d2)
}

mc_call <- function(S0, K, r, sigma, T_, n, seed = NULL) {
  if (!is.null(seed)) set.seed(seed)
  Z <- rnorm(n)
  ST <- S0 * exp((r - 0.5 * sigma^2) * T_ + sigma * sqrt(T_) * Z)
  payoff <- pmax(ST - K, 0)
  disc <- exp(-r * T_) * payoff
  est <- mean(disc)
  se <- sd(disc) / sqrt(n)
  list(estimate = est, se = se,
       ci_lo = est - 1.96 * se, ci_hi = est + 1.96 * se)
}

C_bs <- bs_call(S0, K, r, sigma, T_)
mc_result <- mc_call(S0, K, r, sigma, T_, n = 100000, seed = 42)
```

Pre modelové parametre dostávame analytickú cenu  $C_{BS} = 10.4506$  a Monte Carlo odhad  $\hat{C}_{MC} = 10.4345$  s 95 % konfidenčným intervalom  $[10.3433, 10.5257]$ .

## 4 Validácia: konvergencia Monte Carlo odhadu

### 4.1 Tabuľka konvergenzie

Aby sme overili rýchlosť konvergenzie odhadu Rovnica 6, zopakujme simuláciu pre rôzne hodnoty  $n$ . Výsledky sú zhrnuté v Tabuľka 1.

```
ns <- c(1e2, 1e3, 1e4, 1e5, 1e6)

tab <- do.call(rbind, lapply(ns, function(n) {
  res <- mc_call(S0, K, r, sigma, T_, n, seed = 2026)
  data.frame(n = n, odhad = res$estimate, se = res$se,
             chyba = abs(res$estimate - C_bs))
}))

knitr::kable(
  tab,
  col.names = c("n", "Odhad MC", "Štand. chyba", "|MC - BS|"),
  digits = 5, align = "rrrr"
)
```

Tabuľka 1: Konvergencia Monte Carlo odhadu k Black-Scholesovej cene.

| n     | Odhad MC | Štand. chyba | MC - BS |
|-------|----------|--------------|---------|
| 1e+02 | 9.27585  | 1.42180      | 1.17474 |
| 1e+03 | 10.51848 | 0.47218      | 0.06789 |
| 1e+04 | 10.49570 | 0.15020      | 0.04512 |
| 1e+05 | 10.50374 | 0.04678      | 0.05316 |
| 1e+06 | 10.44387 | 0.01471      | 0.00672 |

Z Tabuľka 1 vidíme, že štandardná chyba aj absolútna odchýlka od analytickej ceny klesajú približne ako  $1/\sqrt{n}$  — pri zvýšení  $n$  o faktor 100 sa chyba zníži približne 10-násobne.

### 4.2 Grafická ilustrácia konvergenzie

Konvergencia bodového odhadu spolu s pásmom 95 % konfidenčného intervalu je znázornená na Obrázok 1.

```
set.seed(2026)
n_max <- 50000
Z <- rnorm(n_max)
ST <- S0 * exp((r - 0.5 * sigma^2) * T_ + sigma * sqrt(T_) * Z)
disc <- exp(-r * T_) * pmax(ST - K, 0)
```


```

cumul_mean <- cumsum(disc) / seq_along(disc)
cumul_var  <- (cumsum(disc^2) - seq_along(disc) * cumul_mean^2) /
              pmax(seq_along(disc) - 1, 1)
cumul_se   <- sqrt(cumul_var / seq_along(disc))

idx <- seq(100, n_max, by = 50)

plot(idx, cumul_mean[idx], type = "l", lwd = 1.5, col = "steelblue",
     ylim = c(C_bs - 1.5, C_bs + 1.5),
     xlab = "počet simulácií n", ylab = "odhad ceny opcie")
polygon(c(idx, rev(idx)),
       c(cumul_mean[idx] - 1.96 * cumul_se[idx],
         rev(cumul_mean[idx] + 1.96 * cumul_se[idx])),
       col = adjustcolor("steelblue", alpha.f = 0.2), border = NA)
abline(h = C_bs, lty = 2, lwd = 1.2)
legend("topright", legend = c("MC odhad", "95 % CI", "BS hodnota"),
     col = c("steelblue", adjustcolor("steelblue", 0.4), "black"),
     lty = c(1, 1, 2), lwd = c(1.5, 6, 1.2), bty = "n")

```



Obrázok 1: Konvergenca Monte Carlo odhadu ceny opcie k analytickej hodnote (čierna prerušovaná čiara) so zväčšujúcim sa počtom simulácií. Šedé pásmo predstavuje 95 % konfidenčný interval.

### 4.3 Bonus: ázijská opcia

Pre exotické opcie analytická formula vo všeobecnosti neexistuje a metóda Monte Carlo sa stáva nevyhnutnou. Ako príklad uvažujme **ázijskú priemerovaciu kúpnu opciu**, ktorej výplata závisí od priemeru ceny počas životnosti opcie:

$$\text{payoff} = (\bar{S} - K)^+, \quad \bar{S} = \frac{1}{m} \sum_{j=1}^m S_{t_j}. \quad (7)$$

```
mc_asian <- function(S0, K, r, sigma, T_, n, m, seed = NULL) {
  if (!is.null(seed)) set.seed(seed)
  dt <- T_ / m
  Z <- matrix(rnorm(n * m), nrow = n, ncol = m)
  log_inc <- (r - 0.5 * sigma^2) * dt + sigma * sqrt(dt) * Z
  log_S <- t(apply(log_inc, 1, cumsum))
  S_paths <- S0 * exp(log_S)
  S_avg <- rowMeans(S_paths)
  payoff <- pmax(S_avg - K, 0)
  disc <- exp(-r * T_) * payoff
  list(estimate = mean(disc), se = sd(disc) / sqrt(n))
}

asian <- mc_asian(S0, K, r, sigma, T_, n = 50000, m = 50, seed = 7)
```

Cena ázijskej opcie (5.8569) je nižšia než cena európskej opcie (10.4506): priemerovanie znižuje volatilitu výplaty, a teda aj cenu opcie (Glasserman 2003, kap. 4).

## 5 Aplikácia na reálne dáta: Apple Inc.

V tejto sekcii aplikujeme obe metódy na akciu **Apple Inc. (NASDAQ: AAPL)**. Dáta sú stiahnuté zo služby Yahoo Finance pomocou packagu **quantmod** a uložené v adresári **data/**. V projekte sú dáta automaticky aktualizované každý deň cez GitHub Actions.

```
prices <- read.csv("data/aapl_prices.csv")
prices$date <- as.Date(prices$date)

# Meta-info
meta_lines <- readLines("data/meta.txt")
meta <- setNames(
  trimws(sub("^[:]+:\\s*", "", meta_lines)),
  trimws(sub(":.*$", "", meta_lines))
)


S0_real <- as.numeric(meta["spot_price"])
spot_date <- meta["spot_date"]
fetched_at <- meta["fetched_at"]
```

Aktuálna cena akcie ku dňu **2026-06-17** je **\$295.95**.

### 5.1 Vývoj ceny akcie

Obrázok 2 zobrazuje vývoj ceny AAPL za posledné 2 roky.

```
plot(prices$date, prices$close, type = "l", lwd = 1.2, col = "steelblue",
     xlab = "dátum", ylab = "zatváracia cena (USD)",
     main = "")
grid(col = "gray80")
abline(h = S0_real, lty = 3, col = "darkgray")
```



Obrázok 2: Vývoj zatváracej ceny AAPL za posledné 2 roky. Dáta: Yahoo Finance.

## 5.2 Odhad volatility z historických dát

Volatilita  $\sigma$  je v Black-Scholesovom modeli kľúčový parameter, ktorý nie je priamo pozorovateľný. Tradičný spôsob jej odhadu je z historických logaritmických denných výnosov

$$r_t = \ln \frac{S_t}{S_{t-1}}. \quad (8)$$

Anualizovaná volatilita sa získa škálovaním smerodajnej odchýlky denných výnosov faktorom  $\sqrt{252}$ , kde 252 je typický počet obchodných dní v roku.

```
log_returns <- diff(log(prices$close))
sigma_daily <- sd(log_returns)
sigma_hist  <- sigma_daily * sqrt(252)

mu_daily    <- mean(log_returns)
mu_annual   <- mu_daily * 252
```


Empirické hodnoty:

- denná smerodajná odchýlka výnosov: 0.0175
- **anualizovaná historická volatilita:**  $\hat{\sigma}_{\text{hist}} = 0.2775$  (27.75 %)
- anualizovaný priemerný výnos: 0.1627

### 5.3 Test predpokladu normality

Black-Scholesov model predpokladá, že logaritmické výnosy sú normálne rozdelené. Obrázok 3 porovnáva empirické rozdelenie výnosov AAPL s prispôbenou normálnou hustotou.

```
hist(log_returns, breaks = 50, freq = FALSE,
     col = adjustcolor("steelblue", 0.6), border = "white",
     xlab = "log výnos", ylab = "hustota", main = "")
xs <- seq(min(log_returns), max(log_returns), length.out = 200)
lines(xs, dnorm(xs, mean = mu_daily, sd = sigma_daily),
      col = "red", lwd = 2)
legend("topright",
      legend = c("empirické dáta", "N(., .^2)"),
      fill = c(adjustcolor("steelblue", 0.6), NA),
      border = c("white", NA),
      lty = c(NA, 1), col = c(NA, "red"), lwd = c(NA, 2),
      bty = "n")
```



Obrázok 3: Histogram denných logaritmických výnosov AAPL s nadprispôbenou normálnou hustotou (červená čiara). Empirické dáta vykazujú výraznejšie chvosty než predpokladá normálne rozdelenie — znak tzv. *fat tails*, dobre známy problém Black-Scholesovho modelu.

Vizuálne aj kvantitatívne (Jarque-Bera test,  $p\text{-hodnota} < 0e + 00$ ) zamietame normalitu výnosov. Špicatosť (kurtóza) je výrazne vyššia než 3 — extrémne pohyby na trhu sa vyskytujú častejšie, než by predpovedalo normálne rozdelenie. Tento jav sa nazýva *fat tails* a je jednou z hlavných výhrad voči Black-Scholesovmu modelu.

## 5.4 Porovnanie modelových cien s trhovými

Teraz aplikujeme obe metódy na konkrétnu sériu kúpnych opcií na AAPL. Dáta sú stiahnuté z aktuálneho option chain.

```
options_path <- "data/aapl_options.csv"
have_options <- file.exists(options_path) &&
                  file.size(options_path) > 0

opts <- read.csv(options_path)

T_real <- as.numeric(meta["years_to_expiry"])
expiry <- meta["option_expiry"]
r_real <- 0.045 # bezrizikova miera ~ 3M T-bill yield

# Implikovaná volatilita: hľadáme sigma t.z. BS(sigma) = market_price.
# Vraciame NA ak cena leží mimo arbitrážnych hraníc alebo bisekcia zlyhá.
implied_vol <- function(market_price, S0, K, r, T_) {
  if (is.na(market_price) || market_price <= 0) return(NA_real_)
  # Arbitrážne hranice:  $\max(0, S - K \cdot e^{-rT}) \leq C \leq S$ 
  lower <- max(0, S0 - K * exp(-r * T_))
  if (market_price < lower * 0.99 || market_price > S0) return(NA_real_)

  f <- function(sigma) bs_call(S0, K, r, sigma, T_) - market_price
  # Hľadáme v intervale (1%, 300%)
  tryCatch({
    res <- uniroot(f, interval = c(0.01, 3.0), tol = 1e-6)
    res$root
  }, error = function(e) NA_real_)
}

# Pre každú opciu spočítame: BS cenu, MC cenu, IV
opts$bs_hist <- bs_call(S0_real, opts$strike, r_real, sigma_hist, T_real)

opts$mc_hist <- sapply(opts$strike, function(K_i) {
  res <- mc_call(S0_real, K_i, r_real, sigma_hist, T_real,
                 n = 50000, seed = 1)
  res$estimate
})

opts$iv_implied <- mapply(function(price, K_i) {
  implied_vol(price, S0_real, K_i, r_real, T_real)
}, opts$market_price, opts$strike)

opts$diff_bs <- opts$market_price - opts$bs_hist

display_tab <- data.frame(
  Strike    = opts$strike,
  Bid       = opts$bid,
  Ask       = opts$ask,
  Last      = opts$last,
```

```

  Trh      = opts$market_price,
  BS       = opts$bs_hist,
  MC       = opts$mc_hist,
  Rozdiel  = opts$diff_bs,
  IV       = opts$iv_implied
)

knitr::kable(display_tab,
  col.names = c("K", "Bid", "Ask", "Last", "Cena trhu",
    "BS ( _hist)", "MC ( _hist)",
    "Trh - BS", "IV"),
  digits = 4, align = "r")

```

Tabuľka 2: Porovnanie trhových cien call opcií na AAPL s modelovými cenami. *Cena trhu* je mid (bid+ask)/2 ak je trh otvorený, inak posledná obchodovaná cena. *BS* a *MC* používajú historickú volatilitu. *IV* je implikovaná volatilita získaná inverziou Black-Scholesovej formule.

| K   | Bid   | Ask   | Last  | Cena trhu | BS ( _hist) | MC ( _hist) | Trh –<br>BS | IV     |
|-----|-------|-------|-------|-----------|-------------|-------------|-------------|--------|
| 210 | 88.25 | 91.00 | 89.68 | 89.625    | 87.6103     | 87.5490     | 2.0147      | 0.5825 |
| 215 | 83.35 | 85.75 | 85.09 | 84.550    | 82.6602     | 82.5996     | 1.8898      | 0.5433 |
| 220 | 77.85 | 80.25 | 79.41 | 79.050    | 77.7190     | 77.6596     | 1.3310      | 0.4747 |
| 225 | 73.60 | 75.10 | 74.59 | 74.350    | 72.7926     | 72.7353     | 1.5574      | 0.4643 |
| 230 | 69.20 | 70.70 | 67.55 | 69.950    | 67.8894     | 67.8332     | 2.0606      | 0.4686 |
| 235 | 63.60 | 66.05 | 64.77 | 64.825    | 63.0208     | 62.9674     | 1.8042      | 0.4295 |
| 240 | 59.75 | 60.80 | 59.98 | 60.275    | 58.2021     | 58.1530     | 2.0729      | 0.4208 |
| 245 | 55.00 | 56.15 | 55.14 | 55.575    | 53.4523     | 53.4092     | 2.1227      | 0.4025 |
| 250 | 50.30 | 50.90 | 50.25 | 50.600    | 48.7939     | 48.7546     | 1.8061      | 0.3714 |
| 255 | 45.60 | 46.30 | 44.36 | 45.950    | 44.2526     | 44.2166     | 1.6974      | 0.3532 |
| 260 | 41.15 | 41.70 | 41.08 | 41.425    | 39.8565     | 39.8296     | 1.5685      | 0.3378 |
| 265 | 36.70 | 37.25 | 37.44 | 36.975    | 35.6344     | 35.6218     | 1.3406      | 0.3225 |
| 270 | 32.45 | 33.00 | 32.51 | 32.725    | 31.6147     | 31.6144     | 1.1103      | 0.3103 |
| 275 | 28.35 | 28.85 | 28.85 | 28.600    | 27.8239     | 27.8371     | 0.7761      | 0.2980 |
| 280 | 24.40 | 25.00 | 24.60 | 24.700    | 24.2847     | 24.3095     | 0.4153      | 0.2875 |
| 285 | 20.90 | 21.25 | 21.00 | 21.075    | 21.0153     | 21.0489     | 0.0597      | 0.2788 |
| 290 | 17.60 | 17.90 | 18.10 | 17.750    | 18.0280     | 18.0686     | -0.2780     | 0.2716 |
| 295 | 14.65 | 14.90 | 14.80 | 14.775    | 15.3289     | 15.3717     | -0.5539     | 0.2661 |
| 300 | 12.00 | 12.25 | 12.08 | 12.125    | 12.9178     | 12.9620     | -0.7928     | 0.2614 |
| 305 | 9.70  | 9.95  | 9.82  | 9.825     | 10.7886     | 10.8302     | -0.9636     | 0.2578 |
| 310 | 7.70  | 7.90  | 7.80  | 7.800     | 8.9297      | 8.9716      | -1.1297     | 0.2536 |
| 315 | 6.10  | 6.30  | 6.25  | 6.200     | 7.3252      | 7.3717      | -1.1252     | 0.2524 |
| 320 | 4.75  | 4.90  | 4.83  | 4.825     | 5.9559      | 6.0080      | -1.1309     | 0.2504 |
| 325 | 3.65  | 3.80  | 3.69  | 3.725     | 4.8002      | 4.8538      | -1.0752     | 0.2492 |
| 330 | 2.78  | 2.90  | 2.84  | 2.840     | 3.8353      | 3.8890      | -0.9953     | 0.2482 |
| 335 | 2.10  | 2.17  | 2.17  | 2.135     | 3.0384      | 3.0916      | -0.9034     | 0.2473 |
| 340 | 1.59  | 1.63  | 1.66  | 1.610     | 2.3870      | 2.4351      | -0.7770     | 0.2475 |
| 345 | 1.20  | 1.25  | 1.24  | 1.225     | 1.8599      | 1.9071      | -0.6349     | 0.2488 |
| 350 | 0.91  | 0.94  | 0.92  | 0.925     | 1.4377      | 1.4820      | -0.5127     | 0.2501 |
| 355 | 0.68  | 0.76  | 0.72  | 0.720     | 1.1026      | 1.1421      | -0.3826     | 0.2532 |

Tabuľka 2: Porovnanie trhových cien call opcií na AAPL s modelovými cenami. *Cena trhu* je  $\text{mid}(\text{bid} + \text{ask})/2$  ak je trh otvorený, inak posledná obchodovaná cena. *BS* a *MC* používajú historickú volatilitu. *IV* je implikovaná volatilita získaná inverziou Black-Scholesovej formule.

| K   | Bid  | Ask  | Last | Cena trhu | BS ( _hist) | MC ( _hist) | Trh –<br>BS | IV     |
|-----|------|------|------|-----------|-------------|-------------|-------------|--------|
| 360 | 0.52 | 0.58 | 0.57 | 0.550     | 0.8392      | 0.8739      | -0.2892     | 0.2554 |
| 365 | 0.38 | 0.45 | 0.42 | 0.415     | 0.6340      | 0.6636      | -0.2190     | 0.2571 |
| 370 | 0.30 | 0.33 | 0.36 | 0.315     | 0.4756      | 0.4972      | -0.1606     | 0.2591 |
| 375 | 0.23 | 0.28 | 0.27 | 0.255     | 0.3542      | 0.3687      | -0.0992     | 0.2637 |
| 380 | 0.18 | 0.24 | 0.19 | 0.210     | 0.2620      | 0.2698      | -0.0520     | 0.2687 |

#### **i** Poznámka

Zdroj cien:  $\text{mid}(\text{bid} + \text{ask})/2$  · Posledná aktualizácia dát: 2026-06-18 18:32:11.754132


## 5.5 Volatility smile

Implikovaná volatilita ako funkcia strike-u zvyčajne nie je konštantná, hoci Black-Scholesov model predpokladá opak. Empiricky pozorovaný tvar sa nazýva **volatility smile** alebo **smirk** (Hull 2018, kap. 20).

```
valid <- !is.na(opts$iv IMPLIED) & opts$iv IMPLIED > 0.05 & opts$iv IMPLIED < 2.0

if (sum(valid) >= 3) {
  # Auto-skala s rozumnym minimom
  iv_range <- range(c(opts$iv IMPLIED[valid], sigma_hist), na.rm = TRUE)
  y_lo <- max(0, iv_range[1] - 0.05)
  y_hi <- iv_range[2] + 0.05

  plot(opts$strike[valid], opts$iv IMPLIED[valid],
       type = "b", pch = 19, col = "steelblue", lwd = 2,
       ylim = c(y_lo, y_hi),
       xlab = "strike K (USD)", ylab = "implikovaná volatilita _imp")
  abline(h = sigma_hist, lty = 2, col = "darkgray", lwd = 1.5)
  abline(v = SO_real, lty = 3, col = "tomato", lwd = 1.5)
  legend("topright",
        legend = c(" implikovaná", " historická", "spot S "),
        col = c("steelblue", "darkgray", "tomato"),
        lty = c(1, 2, 3), lwd = c(2, 1.5, 1.5),
        pch = c(19, NA, NA), bty = "n")
} else {
  plot.new()
  text(0.5, 0.5,
       sprintf("Nedostatok validných opcií pre smile graf (%d).\nSkúste rerun keď je trh otvorený",
               sum(valid)),
       cex = 1.1)
}
```



Obrázok 4: Implikovaná volatilita call opcií AAPL ako funkcia strike-u. Vodorovná čiara označuje historickú volatilitu odhadnutú z výnosov za posledné 2 roky. Zakrivený tvar (smile/smirk) je znakom, že trh oceňuje extrémne pohyby vyššie, než predpokladá Black-Scholesov model s konštantnou volatilitou.

## 5.6 Diskusia výsledkov

Z Tabuľka 2 a Obrázok 4 vyplývajú tri pozorovania:

1. **Modelová cena s historickou volatilitou systematicky podhodnocuje trhové ceny.** Priemerný rozdiel je \$0.330. Trh teda implicitne oceňuje volatilitu vyššie ako historický odhad.
2. **Implikovaná volatilita nie je konštantná.** Krivka v Obrázok 4 má charakteristický tvar smile/smirk: out-of-the-money put a call opcie majú vyššiu IV než at-the-money opcie.
3. **Priemerná implikovaná volatilita** je 0.320 (32.0 %), čo je o 0.043 viac než historická volatilita (0.277). Tento rozdiel sa niekedy nazýva **volatility risk premium**.

Tieto pozorovania motivujú ďalší vývoj v oblasti finančnej matematiky: modely so stochastickou volatilitou (Heston), modely s skokmi (Merton-jump-diffusion) a lokálnou volatilitou (Dupire).

## 6 Záver

V tejto správe sme porovnali dve metódy oceňovania európskej kúpnej opcie: analytickú Black-Scholesovu formulu a numerickú Monte Carlo simuláciu. Empiricky sme overili teoretickú rýchlosť konvergenzie  $\mathcal{O}(1/\sqrt{n})$  — pri  $n = 10^6$  sa Monte Carlo odhad líši od analytickej hodnoty rádovo o tisíce.

Hlavný prínos tejto práce je však v aplikácii oboch metód na **reálne trhové dáta** akcie Apple Inc. Ukázali sme, že:

- empirické rozdelenie denných výnosov AAPL nie je normálne — má výraznejšie chvosty (*fat tails*),
- Black-Scholesov model s historickou volatilitou systematicky podhodnocuje trhové ceny opcií,
- implikovaná volatilita vykazuje charakteristický tvar *volatility smile*, čo priamo protirečí predpokladu modelu o konštantnej volatilitě.

Tieto pozorovania zhrnújú jeden z najdôležitejších poznatkov modernej finančnej matematiky: hoci je Black-Scholes elegantný a stále základným nástrojom, jeho predpoklady sú v reálnom svete porušené, a praktické oceňovanie vyžaduje pokročilejšie modely. Monte Carlo simulácia pritom zostáva univerzálnym nástrojom — funguje rovnako pre Black-Scholes ako aj pre Heston či Merton-jump-diffusion, kde uzavreté formule neexistujú.

Ďalšie smery, ktorými by sa práca dala rozšíriť, zahŕňajú: techniky redukcie rozptylu (antitetické a kontrolné premenné), oceňovanie amerických opcií metódou Longstaff-Schwartz, alebo kalibráciu modelu so stochastickou volatilitou (Glasserman 2003).

## Literatúra

BLACK, Fischer a Myron SCHOLLES, 1973. The Pricing of Options and Corporate Liabilities. *Journal of Political Economy*. 1973, roč. 81, č. 3, s. 637–654.

BOYLE, Phelim P., 1977. Options: A Monte Carlo Approach. *Journal of Financial Economics*. 1977, roč. 4, č. 3, s. 323–338.

GLASSERMAN, Paul, 2003. *Monte Carlo Methods in Financial Engineering*. New York: Springer. ISBN 978-0-387-00451-8.

HULL, John C., 2018. *Options, Futures, and Other Derivatives*. 10. vyd. New York: Pearson. ISBN 978-0-13-447208-9.

MERTON, Robert C., 1973. Theory of Rational Option Pricing. *The Bell Journal of Economics and Management Science*. 1973, roč. 4, č. 1, s. 141–183.